


识迹 / TRACE

AIGC 与学术核查报告


配电网短期负荷对称感知预测方法研究

报告编号：509ab6eca53b46d8b2a069e9089e5856
生成时间：2026-09-16T10:16:26+08:00
检测方法：v71 统计融合版

全文检测总览



段落风险分布



核查范围	本次覆盖情况
文本	提取正文 30102 字；已检测 30102 字；未完成 0 段
图像	送检 9 张；完成 9 张；未定位或排除 0 张
事实与引用	事实条目 20 条；引用已执行核验 20 / 记录 86 条

统计说明

AIGC 倾向字符占比是被分类为 AIGC 倾向的段落字符数占已检测字符数的比例，不是作者使用 AI 的概率。未完成、未检测及证据不足不等于通过。

批注展示阈值：文本风险分类分数 > 50%；疑似 AI 生成图像接口分数 ≥ 80%。未达到阈值的原文不加风险标记，首页统计仍基于全部检测结果。

引用输入修正：[36]、[75]、[86] 的旧核查输入混入页边页码，旧结论已撤下，需重新检测后核查；不表示这些文献已通过核验。

本报告由识迹生成，参考公开检测报告的阅读结构。结果需结合原稿、修订记录和来源人工复核。

01 高置信度风险文本与重点复核

点击蓝色下划线编号，跳转到对应原文与批注。候选分数阈值：80%；高置信度另要求原始置信度为 high 或 ≥ 0.8 ，且非统计降级结果。

本次没有满足高风险与高置信度双重条件的文本。分数高不代表置信度高。

重点人工复核（未达到高置信度条件）

段落编号	原文页码	所在章节	AIGC 倾向分数	置信度
P101	第 38 页	3.3 研究现状分析结论	87.0%	低
P096	第 38 页	3.3 研究现状分析结论	83.0%	低

事实与引用问题定位

类别	编号	原文位置	核查结论	判断来源
事实	C0255	第 32 页	部分支持	模型知识
事实	C0252	第 32 页	不实	模型知识
事实	C0253	第 32 页	部分支持	模型知识
事实	C0123	第 16 页	部分支持	模型知识
事实	C0222	第 28 页	部分支持	模型知识
事实	C0148	第 19 页	部分支持	模型知识
事实	C0107	第 15 页	部分支持	模型知识
事实	C0116	第 15 页	部分支持	模型知识
引用	[44]	参考文献原条目	元数据不一致	联网核查
引用	[50]	参考文献原条目	元数据不一致	模型知识
引用	[72]	参考文献原条目	元数据不一致	模型知识

事实批注区分模型知识判断与联网证据核查。仅因网络或证据不足而无法判断的条目不列为风险；未标记不代表已核验通过。

■ 红色：AIGC / 改写倾向

■ 橙色：AI 润色倾向

蓝线：事实问题

紫线：引用问题

完整依据见页边批注及批注续页

北京航空航天大学

专业博士学位论文开题报告

配电网短期负荷对称感知预测 方法研究

作者姓名 白兰

学科专业 电子信息

指导教师 李波 教授

培养学院 人工智能学院

目 录

1 研究方向概述.....5

1.1 时序模态分解与对称保真表征..... 7

1.2 元启发式智能优化与参数自适应寻优..... 7

1.3 特征关联分析与动态对称筛选..... 8

1.4 对称感知深度时序建模..... 8

1.5 负荷时序三类固有对称性的形式化定义..... 9

2 国内外研究现状..... 12

2.1 时序模态分解类负荷预测研究现状..... 13

2.1.1 经验模态分解类方法的国际发展脉络..... 13

2.1.2 变分模态分解与多元拓展的理论演进..... 14

2.1.3 国内参数寻优与分量后处理研究特色..... 15

2.1.4 国内外对比、文献计量与细分空白..... 16

2.2 Transformer 类深度时序预测模型研究现状.....17

2.2.1 从循环神经网络到注意力机制..... 18

2.2.2 Transformer 及其高效变体的国际演进.....19

2.2.3 Crossformer 与跨维度依赖建模.....21

2.2.4 国内模型融合与轻量化研究..... 22

2.2.5 国内外对比、文献计量与细分空白..... 23

2.3 特征关联分析与元启发式智能优化算法研究现状..... 24

2.3.1 特征关联分析方法研究..... 24

2.3.2 元启发式智能优化算法研究..... 25

2.3.3 混沌策略与算法增强研究..... 26

2.3.4 国内外对比、文献计量与细分空白..... 27

2.4 物理信息嵌入与概率化预测的前沿进展..... 28

2.4.1 物理信息神经网络与领域知识嵌入..... 28

2.4.2 对称性与等变性归纳偏置研究..... 28

2.4.3 概率化与不确定性负荷预测..... 29

3 研究现状总结与分析..... 31

3.1 论文研究领域存在的问题..... 31

3.1.1 模态分解环节：对称约束缺失导致固有特征丢失..... 32

3.1.2 深度建模环节：对称感知缺位导致领域适配不足..... 32

3.1.3 系统协同环节：优化目标割裂导致整体性能受限..... 33

3.2 论文研究领域的发展趋势..... 34

2

文本分数表示相对分类倾向，不是使用 AI 的概率；未标记不代表已核验通过。

报告 509ab6eca53b · 第 4 页

■ 红色 : AIGC / 改写倾向

■ 橙色 : AI 润色倾向

蓝线 : 事实问题

紫线 : 引用问题

完整依据见页边批注及批注续页

3.2.1 趋势一：从被动事后评价转向主动先验约束 34

3.2.2 趋势二：从单一信号处理转向物理信息嵌入的智能建模 34

3.2.3 趋势三：从静态特征筛选转向动态自适应关联感知 35

3.2.4 趋势四：从模块松耦合转向全链路统一目标的紧耦合 35

3.3 研究现状分析结论 35

3.3.1 研究方向一：对称约束型模态分解与对称保真表征 38

3.3.2 研究方向二：混沌增强元启发式优化与参数自适应寻优 39

3.3.3 研究方向三：双向关联对称度分析与动态特征筛选 39

3.3.4 研究方向四：对称感知深度时序建模 39

参考文献 40

图 目

- 图 1 新型电力系统下配电网负荷特性演变现状趋势图
- 图 2 配电网短期符合对称感知预测
- 图 3 对称感知一体化负荷预测研究方向关系图
- 图 4 电力负荷时序三类固有对称性机理示意图
- 图 5 时序模态分解方法演进图与本综述研究定位
- 图 6 Transformer 类深度时序预测模型分类图与本综述改造方向
- 图 7 元启发式智能优化算法寻优性能对比图
- 图 8 现有研究三大共性问题及其内在关联关系图
- 图 9 EnKMA-MVMD-Crossformer 一体化对称感知预测技术路线流程图
- 表 1 研究方向与研究现状对应关系总览

1 研究方向概述

本研究面向新型电力系统建设背景下配电网短期负荷预测的关键需求，聚焦人工智能方法与电力系统时序分析的交叉前沿，核心围绕“负荷对称特征的全链路感知、约束与利用”这一科学命题展开。配电网负荷序列在长期运行中天然蕴含周期对称、频率互补对称与多特征耦合对称三类固有规律，而现有主流方法普遍将其视作普通非平稳时序加以处理，未能将对称先验作为显式的归纳偏置注入预测全流程，导致负荷的本质规律在分解、寻优、建模各环节被反复损耗^[2, 6]。围绕这一核心命题，本研究方向涵盖时序模态分解、元启发式智能优化、特征关联分析与对称感知深度建模四个相互支撑、有机融合的研究分支，共同构建“高质量数据与对称先验—高性能参数寻优—对称保真分解—对称感知深度预测”的递进式技术体系。本章首先界定研究方向的总体背景与四个研究分支及其逻辑关系，明确论文研究分支所涉及的主要研究内容，为第 2 章系统梳理国内外研究现状、第 3 章凝练问题并研判趋势奠定基础。

在我国新型电力系统建设纵深推进、能源数字化转型加速落地的行业背景下，配电网作为电力系统连接电源侧与负荷侧的关键枢纽，其运行形态与负荷特性发生了根本性演变。一方面，分布式光伏、风电、储能、柔性负荷等多元主体大规模、高渗透率接入配电网，使得负荷时序序列呈现强非线性、非平稳性、多尺度振荡与随机扰动加剧等特征；另一方面，工商业、居民、农业等多类型用电主体的差异化用电行为，叠加气象环境、时序节律、社会活动等外部因素的耦合作用，进一步放大了负荷演化的不确定性^[5]。短期负荷预测作为配电网态势感知、经济调度、潮流优化、需求侧响应与分布式新能源消纳的基础性核心支撑技术，其预测精度、鲁棒性与时效性直接决定了配电网运行的安全性、经济性与低碳运行水平^[1, 4]。本综述所研究的对称感知预测框架，正是在这一宏观技术演进趋势之下提出的系统性思路，图 1 直观展示了新型电力系统下配电网负荷特性的演变现状与趋势。

从国家战略与行业政策层面看，构建以新能源为主体的新型电力系统已成为我国能源转型的核心方向，相关规划与行动方案普遍要求提升配电网对分布式新能源的承载与调控能力，并将源网荷储一体化、配电网数字化与智能化升级列为重点任务，对台区级负荷态势感知与高精度短期预测提出了更高要求。这一政策导向共同指向“在高比例分布式电源接入下实现负荷精准预测、灵活调控与安全经济运行”的工程目标，构成了本研究的现实驱动力。

P004

AIGC / 改写倾向

分类分数 62.0%

置信度：低

原文第 5 页

判断依据

- 本段的统计贡献主要集中在“了更高要求”、“已成为”、“的现实”、“这一”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 2 句，平均每句约 98 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。

复核建议

- 回看“了更高要求”、“已成为”、“的现实”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

从国内台区工程落地层面看，现行短期负荷预测仍面临三类突出痛点。其一，含高渗透率分布式光伏的台区，净负荷曲线在午间易出现明显的凹陷与功率倒送现象，相关实测研究表明传统模型对这类强波动、双向潮流场景的预测误差往往明显偏高，难以充分支撑日前调度^[60, 62]。其二，台区量测数据普遍存在采集中断、时标漂移、计量异常等问题，数据质量缺陷直接削弱了预测的稳定性^[55]。其三，新能源出力与负荷的强随机性在一定程度上扰动了传统负荷固有的周期规律，使仅依赖时序依赖建模的方法精度衰减明显^[61]。这些工程痛点共同凸显了在数据扰动与强波动场景下稳健保持负荷固有规律的预测新方法的现实紧迫性，也为以对称先验贯穿全链路的研究思路提供了工程语境。

新型电力系统下配电网负荷特性演变现状趋势




图 1 新型电力系统下配电网负荷特性演变现状趋势图 1

从信号本质来看，电力负荷时序是一类典型的含周期对称、频率对称、特征关联对称的复杂时序信号：日、周、年用电节律构成时序周期对称规律，高低频振荡分量形成频率互补对称关系，气象、日期与负荷之间存在稳定的关联对称特性。然而，当前国内外多数研究仅聚焦负荷的非线性与时序依赖特征，普遍忽略负荷固有的对称先验特征，未能将对称约束、对称感知融入建模全流程，从而导致信号分解失真、特征挖掘不充分、模型泛化能力受限^[2, 6]。为厘清这一研究脉络，本节首先界定研究方向的四个研究分支及其逻辑关系，继而对三类对称性给出可量化的形式化定义，作为后续国内外研究现状评述与问题凝练的客观依据。



图 2 配电网短期符合对称感知预测

1.1 时序模态分解与对称保真表征

该分支聚焦配电网负荷序列的非线性、非平稳与多尺度特性处理，研究如何在将复杂原始负荷分解为若干本征模函数（Intrinsic Mode Function，IMF）分量的同时，保持负荷固有的周期对称与频率互补对称结构不被破坏。其核心研究内容包括：多元变分模态分解（Multivariate Variational Mode Decomposition，MVMD）^[15]的数学机理与约束建模、面向对称保真的变分目标函数重构、分解参数的可量化整定，以及基于样本熵、排列熵的分量复杂度划分与差异化利用^[19, 20, 21]。该分支为后续特征关联分析与深度建模提供高质量、保对称的输入表征，是整个预测框架的信号处理基础。需要强调的是，传统模态分解算法在设计之初均以“信号平稳性”或“复杂度最小化”为单一优化导向，对负荷序列中蕴含的物理对称结构缺乏显式约束。本分支的思路在于将周期对称与频率互补对称作为先验知识，以惩罚项形式嵌入变分目标函数，使分解过程在追求模态正交性与重构精度的同时主动保持负荷固有的对称特征，从而缓解模态分解过程中对称特征损耗这一共性难题。

1.2 元启发式智能优化与参数自适应寻优

该分支聚焦模态分解关键参数与深度模型超参数的全局自动寻优，研究如何突破传统群智能算法在高维、强噪声工程场景下后期收敛慢、易陷局部最优、种群多样性衰退的固有缺陷^[42, 43, 44]。其核心研究内容包括：以新型科莫多龙优化算法（Komodo Mlipir Algorithm，KMA）为基础，融合 Logistic 混沌映射初始化、非线性时变惯性权

图 2

疑似 AI 生成图像

接口分数 98.0%

原文第 7 页

图像说明

配电网短期符合对称感知预测

检测范围

仅提示图像 AI 生成迹象，不代表实验数据造假。

重与 Tent 混沌扰动等多重策略构建混沌增强 KMA (Enhanced KMA, EnKMA) , 并设计兼顾分解精度、模态正交性与计算效率的多目标适应度函数, 为模态分解模态数 K 与惩罚因子 α 的自适应联合寻优提供高性能优化引擎^[46, 47]。在配电网负荷分解场景中, 模态数 K 与惩罚因子 α 的取值对分解质量具有决定性影响: K 取值过小会造成欠分解与模态混叠, 过大则产生虚假模态与过分解; α 取值不当则直接影响各模态带宽与中心频率的分离效果^[14]。传统人工试凑或单一群智能算法寻优难以在高维耦合参数空间中稳定逼近全局最优, 本分支提出的 EnKMA 正是针对这一痛点设计的高鲁棒性寻优工具。

1.3 特征关联分析与动态对称筛选

该分支聚焦多源影响因子与负荷之间关联强度的量化与有效特征筛选, 研究如何刻画气象、日期、环境等因子与负荷的非线性关联及其时变特性。其核心研究内容包括: 基于多元快速最大信息系数 (Multivariate RapidMIC, MVRapidMIC) 的高维特征关联量化、面向极端工况与临时节假日的动态关联识别, 以及结合特征间对称映射规律的定向筛选机制^[36, 37, 38]。该分支不仅为深度模型剔除冗余特征、提供核心特征子集, 更通过构造关联对称度指标, 将特征对称关联作为先验输入传递至对称感知注意力机制。具体而言, 本分支构造因子→负荷与负荷→因子的双向最大信息系数, 并据此定义关联对称度 SP_corr, 用以定向筛选既强关联又信息传递均衡的核心特征; 所得对称关联矩阵进一步作为对称感知注意力偏置的先验输入, 实现特征关联分析模块与深度建模模块之间的有机贯通。

1.4 对称感知深度时序建模

该分支以 Transformer 类深度时序模型为基座, 研究如何将负荷对称先验显式嵌入模型结构, 弥补通用模型在电力负荷领域的适配缺陷。其核心研究内容包括: 在 Crossformer 的维度分段嵌入 (Dimension-Segment-Wise, DSW) 中引入时序周期对称编码以强化周期对称特征表达, 在两阶段注意力 (Two-Stage Attention, TSA) 中构造对称感知注意力偏置以增强多特征交叉对称关联捕捉能力, 并针对不同频率、不同对称特性的 IMF 分量设计差异化输入结构与建模策略, 建立“分分量预测、全局重构”的预测范式^[28, 7]。该分支是框架精度提升的核心引擎, 与前三个分支共同构成“寻优—分解—关联—预测”的紧耦合闭环。

P009

AIGC / 改写倾向

分类分数 60.0%
置信度: 低
原文第 8 页

判断依据

- 本段的统计贡献主要集中在“而言”、“以及”、“并据此”、“特征”等位置, 在两个统计步骤上共同呈现更接近整体改写的相关分布; 单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组, 因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 5 句, 平均每句约 73 字; 低权重辅助统计分别略偏向自然差异和轻度整理, 与最终标签并不完全一致, 说明本段同时存在反向信号, 最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作, 本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准, 跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定, 不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“而言”、“以及”、“并据此”附近的表达及其在相邻段落中的使用: 若多段反复以相同组合组织观点, 应检查是否经过批量改写; 若属于学科固定搭配, 则应降低其解释权重。
- 核对“具体而言”、“进一步”等衔接词是否来自原稿, 还是在后期润色中被集中补入, 并检查删去后论述关系是否仍然成立。
- 本段包含 3 组数字、1 处引文、4 个英文技术标识, 建议与原稿或参考文献逐项核对, 确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显, 人工复核时不要只看语言是否流畅, 应重点比较命题顺序和限定条件是否被重新组织。

上述四个研究分支并非孤立并行，而是以“负荷对称特征”为统一主线层层递进、紧密耦合：智能优化分支为分解分支提供自适应参数寻优能力，分解分支为深度建模分支输出保对称的高质量分量，特征关联分支为深度建模分支提供核心特征与对称关联先验，最终由对称感知深度建模分支完成高精度预测并反向牵引前序各环节的优化目标设计。四者协同构成一套以对称感知为内核、面向配电网短期负荷预测的系统化人工智能方法体系，其总体逻辑关系如图 2 所示。

从研究范式的演进看，短期负荷预测方法大体经历了三个阶段：第一阶段以时间序列分析、回归分析、卡尔曼滤波等经典统计方法为代表，以平稳性假设为前提，模型简单、可解释性强但难以刻画强非线性与多因子耦合；第二阶段以支持向量机、人工神经网络、随机森林等浅层机器学习方法为代表，显著提升了非线性拟合能力，但在长程依赖建模与高维特征处理上仍受限于人工特征工程的质量^[66, 68]；第三阶段则以“信号分解 + 深度学习 + 智能优化”的混合预测框架为代表，通过模态分解降低序列复杂度、借助深度网络挖掘时序与特征依赖、依托智能优化算法自适应整定关键参数，成为当前主流研究范式^[3, 59]。本研究正立足于第三阶段的混合框架，但超越其“模块松耦合、对称特征缺失”的局限：以对称性先验为统一主线，将对称约束、对称感知与对称保真贯穿四大环节，构建全链路紧耦合的一体化框架。这一定位既继承了混合框架在处理复杂负荷场景上的优势，又通过引入对称物理先验弥补了现有方法物理可解释性不足、领域适配性受限的短板，是对现有混合预测范式的深化与发展。





图 3 对称感知一体化负荷预测研究方向关系图

1.5 负荷时序三类固有对称性的形式化定义

为使“对称特征”这一核心概念由定性描述转化为可计算、可验证的量化体系，本节对配电网负荷时序所固有的三类对称性给出明确定义与可量化判据，作为后续对称约束分解与对称感知建模评述的理论基础。设负荷时序为 $x(t)$ （采样长度 N ，周期 T ），其离散序列记为 $x[1..N]$ 。三类对称性的机理示意如图 3 所示。需要在定义之前作一前置澄清：本综述所讨论的三类“对称特征”均属于工程近似对称而非严格数学对称——严格数学对称要求函数满足精确的偶/奇对称或群变换不变性，而本综述所定义的对称本质是人类用电行为节律性重复所带来的统计意义上的镜像近似不变性，其量化判据刻画的是对称的“接近程度”而非“是否成立”，这一定位与负荷的随机性、非平稳性相容，亦与计算机视觉中等变性、不变性等几何归纳偏置研究的基本立场一致^[82, 83]。



- (1) 周期对称（Periodic Symmetry）。指负荷序列在以日、周、年为周期的平移与镜像变换下呈现的近似不变性，本质源于人类用电行为的节律性重复。其量化判据定义为周期镜像残差能量比 SP_{per} ：以周期中点为对称轴，计算同周期内序列与其镜像序列的归一化偏差，即 $SP_{per} = 1 - \|x[t] - x[T-t]\|_2 / \|x[t]\|_2$ ， SP_{per} 越接近 1，周期对称性越强。该指标可结合自相关函数峰值进行交叉验证，从而避免将偶发的相似波形误判为稳定的周期对称结构。
- (2) 频率互补对称（Frequency-Complementary Symmetry）。指负荷信号经模态分解后，各 IMF 分量在频谱能量上呈现的关于主导频率的互补配对关系。设第 k 个分量的频带能量为 E_k ，定义频率互补对称度 SP_{freq} 为高、低频分量能量配对的均

衡程度: $SP_freq = 1 - |\Sigma E_high - \Sigma E_low| / \Sigma E_k$ 。该判据用于衡量分解是否破坏了原始信号高低频能量的互补平衡, 是区别于传统“仅追求平稳性”的关键评价维度。

(3) 特征关联对称 (Feature-Association Symmetry)。指外部影响因子 (气象、日期、环境) 与负荷之间双向信息传递的对称性, 区别于仅刻画线性强度的皮尔逊相关。基于多元快速最大信息系数构造因子 $\rightarrow$ 负荷与负荷 $\rightarrow$ 因子的双向关联 $MIC(f\rightarrow y)$ 与 $MIC(y\rightarrow f)$, 定义关联对称度 SP_corr : $SP_corr = 1 - |MIC(f\rightarrow y) - MIC(y\rightarrow f)| / \max(MIC(f\rightarrow y), MIC(y\rightarrow f))$, 用以定向筛选既强关联又信息传递均衡的核心特征^[36, 38]。

需进一步辨明, 本综述的对称特征与自相关、皮尔逊相关、互信息存在本质差异: 后三者均为“关联强度”度量, 不区分作用方向、不刻画镜像结构; 而周期对称度量序列关于对称轴的镜像结构保持, 频率互补对称度量分量能量关于主频的互补配对, 特征关联对称度量因子与负荷之间双向信息传递的对称性, 刻画的是“结构对称性”, 与“关联强度”指标在物理含义上正交互补^[35, 37]。正因近似对称连续、有界且可微的先验, 方可作为软约束 (惩罚项) 引入变分模态分解: 对称结构被保持时惩罚趋近于零、被破坏时惩罚增大, 从而在不要求严格对称成立的前提下引导分解保真。

(4) 对称保真度 (Symmetry Fidelity, SF)。为统一衡量信号处理 (尤其是模态分解) 前后对称特征的保持程度, 定义对称保真度 SF 为分解重构信号与原始信号三类对称指标的加权保持比例: $SF = \Sigma w_j \cdot (1 - |SP_j^{\wedge rec} - SP_j^{\wedge ori}| / SP_j^{\wedge ori})$, $j \in \{per, freq, corr\}$, 其中 w_j 为各对称分量的权重, $SP_j^{\wedge ori}$ 、 $SP_j^{\wedge rec}$ 分别为原始信号与分解重构信号的对称度。SF 越接近 1, 表明分解越好地保真了负荷固有对称结构。该指标贯穿本综述对分解算法与预测框架的现状评述与价值判断, 是连接“定义—约束—验证”逻辑链路的关键纽带。上述定义将“对称特征”由定性描述转化为可计算、可验证的量化体系, 为后续现状评述中“对称约束缺失”的判断提供客观依据。

在明确研究背景、四个研究分支及三类对称性形式化定义之后, 本综述的现状梳理具备了清晰的评价坐标。下一章将围绕时序模态分解、Transformer 类深度时序预测、特征关联分析与元启发式智能优化三大技术主线, 对国内外研究现状进行系统评述, 并在每一分支内部以国际脉络、国内脉络、横向对比与细分空白四个层次展开, 进而第 3 章凝练共性问题、研判发展趋势、给出研究现状分析结论。

P017

AIGC / 改写倾向

分类分数 51.0%
置信度: 低
原文第 11 页

判断依据

1. 本段的统计贡献主要集中在“并在”、“进而”、“梳理”、“围绕”等位置, 在两个统计步骤上共同呈现更接近整体改写的相关分布; 单个词组本身不是 AIGC 证据。
2. 两步统计在当前段落上均指向较强的表达重组, 因此不是由单一连接词、术语或排版形式触发的结论。
3. 本段可切分为 2 句, 平均每句约 90 字; 低权重辅助统计分别略偏向自然差异和整体重写, 与最终标签并不完全一致, 说明本段同时存在反向信号, 最终结果主要由局部组合决定。

反向证据

1. 正式、流畅、结构完整或术语密集也可能来自正常学术写作, 本次没有把这些表面特征单独作为 AIGC 依据。
2. 当前未使用已知学科的专门校准, 跨学科写作习惯可能影响结果。
3. 数字、引文和英文技术标识可能由研究对象本身决定, 不能因为它们排列规整就推断为 AI 写作。

复核建议

1. 回看“并在”、“进而”、“梳理”附近的表达及其在相邻段落中的使用: 若多段反复以相同组合组织观点, 应检查是否经过批量改写; 若属于学科固定搭配, 则应降低其解释权重。
2. 本段包含 1 组数字、1 个英文技术标识, 建议与原稿或参考文献逐项核对, 确认改写没有改变数值、对象及限定条件。
3. 本段长短句差异较明显, 人工复核时不要只看语言是否流畅, 应重点比较命题顺序和限定条件是否被重新组织。

2 国内外研究现状

配电网短期负荷预测是电力系统运行调度、需求侧管理与新能源消纳的重要基础。围绕这一问题，国内外学者在时序模态分解、深度时序预测模型、特征关联分析与元启发式智能优化等方向开展了大量研究，形成了从传统统计方法到混合智能预测框架的完整技术演进脉络^[2, 5, 6]。从方法论角度审视，短期负荷预测方法的发展大体经历了三个阶段：第一阶段以时间序列分析、回归分析、卡尔曼滤波等经典统计方法为代表，模型结构简单、可解释性强，但难以刻画负荷的强非线性与多因子耦合特性；第二阶段以支持向量机、人工神经网络、随机森林等浅层机器学习方法为代表，显著提升了非线性拟合能力，但在长程依赖建模与高维特征处理方面仍存在瓶颈^[66, 68]；第三阶段则以“信号分解 + 深度学习 + 智能优化”的混合预测框架为代表，通过模态分解降低序列复杂度、借助深度网络挖掘时序与特征依赖、依托智能优化算法自适应整定关键参数，成为当前该领域的主流研究范式^[3, 59, 67]。本研究立足于第三阶段的混合预测框架，但超越了现有框架“模块松耦合、对称特征缺失”的局限，因此本章的现状评述亦围绕这一范式的四大功能模块依次展开。

为兼顾理论根基与现状评述的连贯性，本章在分支评述之前先行界定短期负荷预测的基本概念、影响因素与方法演进定位。电力负荷预测是指根据历史负荷数据及相关影响因素，运用数学模型与算法对未来某一时段的电力需求进行定量估计的过程；按预测时间尺度可分为超短期、短期、中期与长期四类，其中短期负荷预测以未来数小时至数天的负荷为对象，是配电网日前调度、机组组合、潮流优化与需求侧响应的核心支撑^[1, 4]。在新型电力系统背景下，配电网负荷呈现强非线性、非平稳性、多尺度振荡与随机扰动加剧的复杂特性：强非线性源于负荷与气温、湿度等影响因子之间复杂的耦合关系，非平稳性表现为统计特征随时间变化的时变特性，多尺度振荡体现为日、周、年等多周期成分的叠加，随机扰动则来自分布式电源出力波动与用户行为不确定性^[55, 61]。这些特性使得传统单一模型难以准确刻画负荷演化规律，催生了以“分解 + 深度学习 + 优化”为代表的混合框架，也构成了本章按技术分支评述的逻辑前提。

配电网负荷的演化是多因子耦合作用的结果，准确识别并量化各类影响因素是提升预测精度的前提。负荷的主要影响因素可归纳为四类：气象因素（温度、湿度、风速、太阳辐射等，其中温度对负荷影响最为显著且呈明显非线性特征）、时间因素（小时、星期、月份、季节等，体现日、周、年周期节律）、日期类型因素（工作

P019

AIGC / 改写倾向

分类分数 73.0%

置信度：低

原文第 12 页

判断依据

1. 本段的统计贡献主要集中在“，显著提升了”、“仍存在”、“围绕这”、“绕这一”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
2. 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
3. 本段可切分为 3 句，平均每句约 84 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

1. 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
2. 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
3. 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

1. 回看“，显著提升了”、“仍存在”、“围绕这”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
2. 核对“因此”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
3. 本段包含 5 组数字、2 处引文，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
4. 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

日、休息日、法定节假日及临时调休等）与社会经济因素（产业结构、经济活动水平、电价政策等）^[1, 57]。值得注意的是，气象、日期等外部因子与负荷之间不仅存在单向的因果影响，更存在稳定的双向信息传递关系——这一关联结构正是本研究构造关联对称度指标、实现对称感知建模的物理基础，也使得本章对特征关联分析现状的评述具有明确的方法论指向。

2.1 时序模态分解类负荷预测研究现状

时序模态分解是处理电力负荷非平稳、多尺度、强波动特性的核心前置技术，其基本思想是将复杂的原始负荷序列分解为若干具有单一频率、相对平稳周期的本征模函数分量，通过“分量建模、结果重构”的策略降低单一模型的拟合难度，已成为当前混合预测框架的主流基础模块^[3, 56]。负荷预测精度在很大程度上取决于分解算法能否在抑制模态混叠的同时保留负荷的固有物理特征，这一目标贯穿了时序分解技术的整个发展历程。从早期的经验模态分解到具有严格数学框架的变分模态分解，再到面向多源耦合时序的多元变分模态分解，时序分解方法的演进始终遵循“自适应性增强—理论严谨性提升—多变量处理能力拓展”的内在逻辑，其方法演进脉络与本综述研究定位如图所示。



图 5 时序模态分解方法演进图与本综述研究定位

2.1.1 经验模态分解类方法的国际发展脉络

国际上，时序分解方法的发展始于 Huang 等人提出的经验模态分解（Empirical Mode Decomposition，EMD）^[9]。EMD 凭借完全数据驱动、无需预设基函数的自适应分解特性，被广泛应用于能源时序、机械故障诊断等非平稳信号分析领域^[11]。其核心思想是通过对信号上下包络均值的逐次“筛分”，将原始信号自适应分解为若干阶本征模函数与一个残余趋势项，每个 IMF 分量满足极值点数目与过零点数目相差不超过

1、上下包络均值为零两项条件，从而具备明确的瞬时频率物理意义。然而，EMD 存在固有的端点效应与模态混叠问题，且对噪声敏感、缺乏严格的数学理论支撑。所谓模态混叠，是指同一阶 IMF 中混入了尺度差异显著的信号成分，或同一尺度的信号被分散到不同阶 IMF 中，这会严重破坏分解结果的物理可解释性。为缓解模态混叠，Wu 与 Huang 提出集合经验模态分解（Ensemble EMD，EEMD）^[10]，通过向原信号多次添加白噪声并对分解结果取均值来抑制混叠，其理论依据是白噪声在多次集合平均后趋于抵消，而信号的真实模态结构得以保留。在此基础上，Torres 等人进一步提出自适应噪声完备集合经验模态分解（CEEMDAN）及其改进版本（ICEEMDAN）^[12, 13]，在每一阶分解中自适应添加特定噪声并完成完备重构，在减少残余噪声、降低虚假模态方面取得显著进展，成为早期国际主流的分解方法。

这类方法在电力负荷预测中得到广泛验证，例如 Gao 等人将 EMD 与门控循环单元结合并辅以特征选择，验证了解对负荷预测精度的提升作用^[65]；国内学者亦将 CEEMDAN 与长短期记忆网络相结合用于短期负荷预测，取得了良好效果^[56]。但 EMD 类方法的本质仍为递归筛分，缺乏明确的优化目标，分解结果的可重复性与稳定性受参数与噪声实现影响较大，且端点效应在序列首尾段的失真问题始终难以彻底消除。重要的是从对称保真的视角审视，EMD 类方法在筛分过程中对负荷固有的周期镜像结构与高低频能量配对关系不施加任何约束，分解所得分量的对称保真度 SF 高度依赖于信号自身特性与噪声实现，难以稳定保持，这一局限在现有文献中尚未被系统讨论。

具体到对称失真的机理，EMD 类方法的端点效应在序列首尾缺乏完整周期信息时，往往通过包络外延或镜像延拓加以近似处理，而这种近似本身会在边界处引入虚假的对称或非对称结构，使得首尾时段的周期镜像残差能量比偏离真实值；与此同时，集合平均策略虽能抑制模态混叠，却也会在不同噪声实现之间对高低频分量的能量分配产生随机扰动，导致频率互补对称度在多次分解之间出现波动。换言之，EMD 类方法对称特征的损耗并非来自某一确定性误差，而是源于递归筛分缺乏全局约束的内在机制，这决定了仅靠改良噪声添加策略难以从根本上保证对称保真，必须从分解的优化目标层面引入显式的对称约束，方能稳定地维持负荷的固有对称结构。

2.1.2 变分模态分解与多元拓展的理论演进

为给模态分解赋予严格的数学框架，Dragomiretskiy 与 Zosso 提出变分模态分解 (Variational Mode Decomposition, VMD) ^[14]，将分解问题转化为约束变分问题，通过交替方向乘子法 (Alternating Direction Method of Multipliers, ADMM) 迭代求解各模态的中心频率与带宽，从理论上克服了 EMD 类方法的递归误差累积与端点效应，具备更强的噪声鲁棒性与模态分离能力。VMD 的核心在于：假定信号由 K 个具有有限带宽、围绕各自中心频率紧凑分布的本征模态构成，通过 Hilbert 变换计算各模态的解析信号并解调至基带，以各模态梯度 L2 范数之和最小化为目标，在各模态之和等于原信号的约束下完成分解。这一变分建模思想使分解过程具备了明确的优化目标与收敛保证，是模态分解理论的重要里程碑，也为在目标函数中引入额外先验约束（如对称保真约束）提供了可行的数学接口^[49]。

针对单变量 VMD 无法处理多源耦合时序的缺陷，Rehman 与 Aftab 提出多元变分模态分解 (MVMD) ^[15]，将 VMD 拓展至多元时序场景，通过多通道同步分解保留多变量之间的振荡关联与耦合特征，使各通道在相同中心频率下对齐分解，目前已成为欧美电力负荷、风电功率预测领域的主流分解算法。在配电网负荷预测中，MVMD 能够同步处理负荷、温度、湿度等多维时序，保留其在频域上的耦合振荡关系，相较单变量分解更契合多因子耦合的负荷演化机理^[18]。然而，国外现有研究多采用人工试凑法确定 MVMD 的分解模态数 K 与二次惩罚因子 α ，参数选取缺乏量化准则，分解质量高度依赖经验；同时，分解过程未考虑负荷序列固有的周期对称、频率互补对称特性，目标函数中并不包含任何对称结构的保持项，因而在模态正交性与重构精度之外，对称特征的损耗与畸变缺乏显式控制，易造成对称特征丢失与分量畸变。这一缺口正是本综述将对称保真约束嵌入 MVMD 变分目标的直接动因。

2.1.3 国内参数寻优与分量后处理研究特色

国内学者针对 VMD/MVMD 参数寻优、二次分解与分量后处理开展了大量深耕研究，形成了具有鲜明特色的技术路线。其主流思路为引入粒子群优化、麻雀搜索算法、灰狼优化等群智能算法实现分解参数的自适应寻优，以平均包络熵、模态混叠系数等为适应度指标，在一定程度上摆脱了人工调参的依赖，提升了分解结果的稳定性^[40, 41, 42, 45]。其中，平均包络熵反映了 IMF 分量的稀疏特性与冲击成分含量，包络熵越小，分量的周期冲击特征越显著、噪声成分越少，因而被广泛用作衡量分解质量的核心指标。代表性工作如孙波等人将改进 VMD 与混合神经网络结合用于短期负荷预测

C0107

事实核查：部分支持

判断来源：模型知识（未作联网查实）
置信度：90%
原文第 15 页

判断理由

VMD由Dragomiretskiy与Zosso提出，采用约束变分框架和ADMM求解中心频率及带宽，这部分正确；但称其从理论上克服EMD端点效应和递归误差、并必然具有更强鲁棒性和分离能力，属于过强比较。

为给模态分解赋予严格的数学框架，Dragomiretskiy 与 Zosso 提出变分模态分解（Variational Mode Decomposition，VMD）^[14]，将分解问题转化为约束变分问题，通过交替方向乘子法（Alternating Direction Method of Multipliers，ADMM）迭代求解各模态的中心频率与带宽，从理论上克服了 EMD 类方法的递归误差累积与端点效应，具备更强的噪声鲁棒性与模态分离能力。VMD 的核心在于：假定信号由 K 个具有有限带宽、围绕各自中心频率紧凑分布的本征模态构成，通过 Hilbert 变换计算各模态的解析信号并解调至基带，以各模态梯度 L2 范数之和最小化为目标，在各模态之和等于原信号的约束下完成分解。这一变分建模思想使分解过程具备了明确的优化目标与收敛保证，是模态分解理论的重要里程碑，也为在目标函数中引入额外先验约束（如对称保真约束）提供了可行的数学接口^[49]。

针对单变量 VMD 无法处理多源耦合时序的缺陷，Rehman 与 Aftab 提出多元变分模态分解（MVMD）^[15]，将 VMD 拓展至多元时序场景，通过多通道同步分解保留多变量之间的振荡关联与耦合特征，使各通道在相同中心频率下对齐分解，目前已成为欧美电力负荷、风电功率预测领域的主流分解算法。在配电网负荷预测中，MVMD 能够同步处理负荷、温度、湿度等多维时序，保留其在频域上的耦合振荡关系，相较单变量分解更契合多因子耦合的负荷演化机理^[18]。然而，国外现有研究多采用人工试凑法确定 MVMD 的分解模态数 K 与二次惩罚因子 α ，参数选取缺乏量化准则，分解质量高度依赖经验；同时，分解过程未考虑负荷序列固有的周期对称、频率互补对称特性，目标函数中并不包含任何对称结构的保持项，因而在模态正交性与重构精度之外，对称特征的损耗与畸变缺乏显式控制，易造成对称特征丢失与分量畸变。这一缺口正是本综述将对称保真约束嵌入 MVMD 变分目标的直接动因。

2.1.3 国内参数寻优与分量后处理研究特色

国内学者针对 VMD/MVMD 参数寻优、二次分解与分量后处理开展了大量深耕研究，形成了具有鲜明特色的技术路线。其主流思路为引入粒子群优化、麻雀搜索算法、灰狼优化等群智能算法实现分解参数的自适应寻优，以平均包络熵、模态混叠系数等为适应度指标，在一定程度上摆脱了人工调参的依赖，提升了分解结果的稳定性^[40, 41, 42, 45]。其中，平均包络熵反映了 IMF 分量的稀疏特性与冲击成分含量，包络熵越小，分量的周期冲击特征越显著、噪声成分越少，因而被广泛用作衡量分解质量的核心指标。代表性工作如孙波等人将改进 VMD 与混合神经网络结合用于短期负荷预测

P029

AIGC / 改写倾向

分类分数 59.0%
置信度：低
原文第 15 页

判断依据

- 本段的统计贡献主要集中在“已成为”、“然而，”、“特征”、“同步”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 5 句，平均每句约 81 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“已成为”、“然而，”、“特征”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“因而”、“同时”、“然而”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 2 组数字、2 处引文、9 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

为给模态分解赋予严格的数学框架，Dragomiretskiy 与 Zosso 提出变分模态分解 (Variational Mode Decomposition, VMD) ^[14]，将分解问题转化为约束变分问题，通过交替方向乘子法 (Alternating Direction Method of Multipliers, ADMM) 迭代求解各模态的中心频率与带宽，从理论上克服了 EMD 类方法的递归误差累积与端点效应，具备更强的噪声鲁棒性与模态分离能力。VMD 的核心在于：假定信号由 K 个具有有限带宽、围绕各自中心频率紧凑分布的本征模态构成，通过 Hilbert 变换计算各模态的解析信号并解调至基带，以各模态梯度 L2 范数之和最小化为目标，在各模态之和等于原信号的约束下完成分解。这一变分建模思想使分解过程具备了明确的优化目标与收敛保证，是模态分解理论的重要里程碑，也为在目标函数中引入额外先验约束（如对称保真约束）提供了可行的数学接口^[49]。

针对单变量 VMD 无法处理多源耦合时序的缺陷，Rehman 与 Aftab 提出多元变分模态分解 (MVMD) ^[15]，将 VMD 拓展至多元时序场景，通过多通道同步分解保留多变量之间的振荡关联与耦合特征，使各通道在相同中心频率下对齐分解，目前已成为欧美电力负荷、风电功率预测领域的主流分解算法。在配电网负荷预测中，MVMD 能够同步处理负荷、温度、湿度等多维时序，保留其在频域上的耦合振荡关系，相较单变量分解更契合多因子耦合的负荷演化机理^[18]。然而，国外现有研究多采用人工试凑法确定 MVMD 的分解模态数 K 与二次惩罚因子 α ，参数选取缺乏量化准则，分解质量高度依赖经验；同时，分解过程未考虑负荷序列固有的周期对称、频率互补对称特性，目标函数中并不包含任何对称结构的保持项，因而在模态正交性与重构精度之外，对称特征的损耗与畸变缺乏显式控制，易造成对称特征丢失与分量畸变。这一缺口正是本综述将对称保真约束嵌入 MVMD 变分目标的直接动因。

2.1.3 国内参数寻优与分量后处理研究特色

国内学者针对 VMD/MVMD 参数寻优、二次分解与分量后处理开展了大量深耕研究，形成了具有鲜明特色的技术路线。其主流思路为引入粒子群优化、麻雀搜索算法、灰狼优化等群智能算法实现分解参数的自适应寻优，以平均包络熵、模态混叠系数等为适应度指标，在一定程度上摆脱了人工调参的依赖，提升了分解结果的稳定性^[40, 41, 42, 45]。其中，平均包络熵反映了 IMF 分量的稀疏特性与冲击成分含量，包络熵越小，分量的周期冲击特征越显著、噪声成分越少，因而被广泛用作衡量分解质量的核心指标。代表性工作如孙波等人将改进 VMD 与混合神经网络结合用于短期负荷预测

C0116

事实核查：部分支持

判断来源：模型知识（未作联网查实）
置信度：86%
原文第 15 页

判断理由

包络熵常用于描述复杂度或稀疏性并作为分解评价指标，但其越小并不普遍等价于冲击特征更显著、噪声更少；“广泛核心指标”也缺少统一标准。

^[16], 马辉等人将 MVMD 用于故障诊断并验证其多通道耦合保持能力^[17], 均反映出国内研究对分解算法工程适配性的高度重视。

在分量后处理方面, 部分学者结合样本熵、排列熵、模糊熵^[19, 20, 21]等复杂度度量对 IMF 分量进行量化划分, 区分高频随机分量、中频周期分量与低频趋势分量, 进而实现高低频分量的差异化建模, 有效抑制了高频随机噪声对预测精度的干扰。具体而言, 低频趋势分量通常承载负荷的长期变化规律, 适合采用拟合能力强、参数较多的模型; 高频随机分量则波动剧烈、规律性弱, 宜采用轻量化模型或直接平滑处理, 以避免过拟合^[56, 65]。值得注意的是, 国内研究已开始关注分解算法与电力信号物理特征的结合, 但针对负荷对称特征的约束型分解研究仍较为薄弱、尚不充分, 分解过程对负荷周期对称与频率互补对称结构的保真问题尚未被纳入优化目标, 这正是本综述研究的切入点之一。

2.1.4 国内外对比、文献计量与细分空白

总体来看, 国际研究在分解算法的理论创新与数学严谨性方面处于领先地位, 从 EMD、EEMD、CEEMDAN 到 VMD、MVMD 的演进, 奠定了时序分解的方法学基础; 而国内研究则在参数自适应寻优、分量差异化建模与工程场景适配方面更具优势, 推动了分解技术在电力负荷预测中的落地。从文献分布上看, 本分支所涉文献在时间上呈现“1998—2014 年集中于 EMD/VMD 类奠基性方法、2019 年后转向 MVMD 多元拓展与群智能参数寻优”的演进特征, 在来源上则呈现“奠基性理论方法多见于信号处理领域国际期刊、工程落地与参数寻优改进多见于国内电力期刊与学位论文”的分布格局, 反映出该分支理论创新与工程适配在国际、国内之间的分工。

尽管成果丰硕, 两类研究仍存在一个共性短板: 均将模态分解视为单纯的信号去噪与降维手段, 以平稳性、复杂度最小化为单一优化目标, 未将对称约束作为分解的先验条件引入。这导致负荷时序固有的周期对称结构与频率互补对称结构在分解阶段即被破坏, 核心物理特征被损耗, 后续建模难以恢复, 成为制约混合预测框架性能进一步突破的根本瓶颈之一。本综述据此提出对称约束型 MVMD, 在变分目标函数中显式嵌入对称保真约束项, 并借助 EnKMA 实现分解参数的自适应联合寻优, 从信号处理层面缓解对称特征丢失问题, 其与现有方法的本质区别在于: 将“对称保真”由被动的事后评价转化为主动的分解约束。

P033

AIGC / 改写倾向

分类分数 51.0%
置信度: 低
原文第 16 页

判断依据

- 本段的统计贡献主要集中在“究仍存在一个”、“难以”、“约束”、“条件”等位置, 在两个统计步骤上共同呈现更接近整体改写的相关分布; 单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组, 因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 3 句, 平均每句约 91 字; 低权重辅助统计分别略偏向自然差异和整体重写, 与最终标签并不完全一致, 说明本段同时存在反向信号, 最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作, 本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准, 跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定, 不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“究仍存在一个”、“难以”、“约束”附近的表达及其在相邻段落中的使用: 若多段反复以相同组合组织观点, 应检查是否经过批量改写; 若属于学科固定搭配, 则应降低其解释权重。
- 核对“进一步”等衔接词是否来自原稿, 还是在后期润色中被集中补入, 并检查删去后论述关系是否仍然成立。
- 本段包含 2 个英文技术标识, 建议与原稿或参考文献逐项核对, 确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显, 人工复核时不要只看语言是否流畅, 应重点比较命题顺序和限定条件是否被重新组织。

^[16]，马辉等人将 MVMD 用于故障诊断并验证其多通道耦合保持能力^[17]，均反映出国内研究对分解算法工程适配性的高度重视。

在分量后处理方面，部分学者结合样本熵、排列熵、模糊熵^[19, 20, 21]等复杂度度量对 IMF 分量进行量化划分，区分高频随机分量、中频周期分量与低频趋势分量，进而实现高低频分量的差异化建模，有效抑制了高频随机噪声对预测精度的干扰。具体而言，低频趋势分量通常承载负荷的长期变化规律，适合采用拟合能力强、参数较多的模型；高频随机分量则波动剧烈、规律性弱，宜采用轻量化模型或直接平滑处理，以避免过拟合^[56, 65]。值得注意的是，国内研究已开始关注分解算法与电力信号物理特征的结合，但针对负荷对称特征的约束型分解研究仍较为薄弱、尚不充分，分解过程对负荷周期对称与频率互补对称结构的保真问题尚未被纳入优化目标，这正是本综述研究的切入点之一。

2.1.4 国内外对比、文献计量与细分空白

总体来看，国际研究在分解算法的理论创新与数学严谨性方面处于领先地位，从 EMD、EEMD、CEEMDAN 到 VMD、MVMD 的演进，奠定了时序分解的方法学基础；而国内研究则在参数自适应寻优、分量差异化建模与工程场景适配方面更具优势，推动了分解技术在电力负荷预测中的落地。从文献分布上看，本分支所涉文献在时间上呈现“1998—2014 年集中于 EMD/VMD 类奠基性方法、2019 年后转向 MVMD 多元拓展与群智能参数寻优”的演进特征，在来源上则呈现“奠基性理论方法多见于信号处理领域国际期刊、工程落地与参数寻优改进多见于国内电力期刊与学位论文”的分布格局，反映出该分支理论创新与工程适配在国际、国内之间的分工。

尽管成果丰硕，两类研究仍存在一个共性短板：均将模态分解视为单纯的信号去噪与降维手段，以平稳性、复杂度最小化为单一优化目标，未将对称约束作为分解的先验条件引入。这导致负荷时序固有的周期对称结构与频率互补对称结构在分解阶段即被破坏，核心物理特征被损耗，后续建模难以恢复，成为制约混合预测框架性能进一步突破的根本瓶颈之一。本综述据此提出对称约束型 MVMD，在变分目标函数中显式嵌入对称保真约束项，并借助 EnKMA 实现分解参数的自适应联合寻优，从信号处理层面缓解对称特征丢失问题，其与现有方法的本质区别在于：将“对称保真”由被动的事后评价转化为主动的分解约束。

C0123

事实核查：部分支持

判断来源：模型知识（未作联网查实）
置信度：90%
原文第 16 页

判断理由

对经典分解方法未显式采用对称约束的概括可能适用于部分文献，但“均为单一目标”及由此必然破坏对称、形成根本瓶颈均属过度概括。

为更清晰地刻画时序分解方法在能力维度上的演进与差异，可从五个关键维度对主流分解方法加以横向归纳：在自适应性方面，EMD 类方法完全数据驱动、无需预设基函数，而 VMD/MVMD 类方法需预设模态数 K ，自适应性相对较弱但可借助智能优化弥补；在数学严谨性方面，EMD 类缺乏严格收敛理论，VMD/MVMD 类则建立在约束变分与 ADMM 求解的坚实数学框架之上^[14, 49]；在噪声鲁棒性方面，EEMD/CEEMDAN 通过集合平均缓解噪声敏感，VMD 凭借带宽约束具备更稳健的抗噪能力；在多变量处理能力方面，仅 MVMD 等多元方法能够同步分解多通道并保持通道间耦合^[15]；在对称保真能力方面，迄今主流方法均无显式机制，对称结构的保持完全依赖信号自身特性与参数选取，呈现系统性缺位。这一横向归纳清晰表明，对称保真能力是贯穿各类分解方法的共同薄弱维度，亦是本研究着力补强的方向。

从更深层的机理看，主流分解方法在对称保真维度上的系统性缺位，根源在于其优化目标的设计哲学与对称保真目标之间存在内在张力。EMD 类方法以包络均值逐次筛分为驱动，其隐含目标是使各分量满足局部对称的窄带条件，但这种局部对称针对的是单个 IMF 的瞬时频率物理意义，而非整条负荷序列关于周期中点的全局镜像对称，二者作用尺度截然不同；VMD/MVMD 类方法以各模态梯度 L_2 范数之和最小化为目标，本质上追求的是模态在频域上的紧凑性与带宽最小化，这一目标在数学上与序列的时域镜像对称、频域能量互补配对并不存在必然的正相关关系，甚至在某些情形下追求带宽最小可能以牺牲高低频能量配对均衡为代价。换言之，现有分解目标函数的优化方向与对称保真目标并非天然一致，仅依靠调整既有目标的权重或参数难以稳定提升对称保真度，必须在变分目标中显式增设独立的对称约束项，方能在求解过程中主动牵引分解结果向保对称方向收敛。这一机理分析进一步印证了将对称保真由被动评价转化为主动分解约束的必要性与不可替代性。

2.2 Transformer 类深度时序预测模型研究现状

自注意力机制的提出推动 Transformer 模型成为长时序数据建模的标杆架构，其凭借强大的全局依赖捕捉能力，逐步取代循环神经网络（RNN、LSTM、GRU），成为电力负荷、新能源功率预测的主流深度学习模型^[7, 8]。深度时序预测模型的演进，始终围绕“如何在控制计算复杂度的同时更充分地刻画时序与特征维度的复杂依赖”这一核心命题展开。从循环结构到注意力机制、从全局密集注意力到稀疏高效注意力、从单

一时序维度建模到跨维度依赖建模，模型架构的每一次革新都在精度与效率的权衡中向前推进，其分类谱系与本综述改造方向如图所示。




图 6 Transformer 类深度时序预测模型分类图与本综述改造方向

2.2.1 从循环神经网络到注意力机制

在 Transformer 出现之前，循环神经网络及其变体长期占据时序预测的主导地位。

Hochreiter 与 Schmidhuber 提出的长短期记忆网络（LSTM）^[22]通过引入输入门、遗忘门、输出门三重门控机制以及细胞状态，有效缓解了传统 RNN 的梯度消失与梯度爆炸问题，使模型能够捕捉较长的时序依赖关系，成为时序预测领域应用最为广泛的基础模型之一。Cho 等人提出的门控循环单元（GRU）^[23]将 LSTM 的三门结构简化为更新门与重置门两门结构，在保持相近性能的同时显著减少了参数量与计算开销，更适合资源受限场景。

在负荷预测领域，Kong 等人系统验证了 LSTM 在居民负荷预测中的有效性^[51]，指出 LSTM 能够较好地刻画居民用户的日周期用电模式；Shi 等人针对居民负荷高波动、易过拟合的特点，提出池化深度 RNN^[52]，通过对相似用户负荷进行池化聚合扩充训练样本，显著缓解了过拟合问题；Sehovac 与 Grolinger 引入注意力机制的序列到序列 RNN^[53]，通过为不同历史时刻分配差异化权重，进一步提升了预测精度；Wang 等人则在双向 LSTM 中引入注意力机制与滚动更新策略，提升了短期负荷预测的稳定性^[63]。然而，循环结构固有的串行计算特性限制了模型的并行训练效率，且在超长序

P037

AI 润色倾向

分类分数 68.0%
置信度：低
原文第 18 页

判断依据

- 统计贡献集中在“前”、“长期”等位置，使文本呈现经过修改的倾向；“出现”附近的组合又更接近轻度整理一侧，联合结果落在 AI 润色区间。
- 两步统计分别呈现“经过修改”与“未形成深度重写”的方向，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 1 句，平均每句约 40 字；低权重辅助统计分别略偏向经过变换和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 本段只有约 41 个有效字符，可观察到的局部模式较少，分类稳定性有限。

复核建议

- 回看“前”、“长期”、“出现”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段包含 1 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

列上仍存在长程依赖衰减问题，难以满足配电网多步、长周期预测对建模能力与计算效率的双重需求。

围绕循环网络在负荷预测中的工程优化，国内外学者还开展了大量改进与拓展工作，进一步丰富了深度负荷预测的方法谱系。Bouktif 等人将遗传算法与特征选择引入 LSTM 超参数整定，构建了面向电力负荷的优化型 LSTM 模型，验证了进化优化对深度模型预测精度的提升作用^[54]；Chen 等人提出基于深度残差网络的短期负荷预测方法，通过残差连接缓解深层网络的退化问题并增强多尺度特征表达^[64]；Fan 等人系统评估了多种深度循环网络策略在建筑能耗短期预测中的适用性，为循环结构的工程选型提供了实证依据^[70]；Memarzadeh 与 Keynia 则提出一种新型最优 LSTM-NN 预测算法，将负荷与电价联合建模并以智能优化整定网络结构^[71]。在不确定性刻画方面，Sun 等人面向副产煤气流量预测构建了基于优化双子极限学习机的预测区间方法，其区间构造思路对负荷概率预测具有借鉴意义^[69]。这些工作虽在网络结构与优化策略上各具特色，但其建模对象仍以时序依赖与多因子统计关联为主，普遍未将负荷固有的对称物理规律纳入模型设计。需要补充说明的是，上述深度模型的训练与验证高度依赖高质量的公开负荷数据集（如 UMass Smart* 等智能电表数据集^[72]），而真实台区数据普遍存在的质量缺陷，进一步凸显了在数据扰动下稳健保持负荷固有规律的研究价值。此外，现代深度时序框架的工程实现亦受益于通用神经网络建模工具链的发展^[50]，为复杂混合预测框架的快速搭建与复现提供了支撑。

2.2.2 Transformer 及其高效变体的国际演进

Vaswani 等人提出的 Transformer 以纯注意力机制取代循环结构^[7]，通过自注意力计算序列内任意两个位置之间的依赖关系，实现了序列的并行处理与全局依赖建模，迅速成为时序建模的主流范式。然而，原始 Transformer 存在计算复杂度随序列长度平方增长、长时序建模效率低的缺陷，难以直接应用于配电网长周期负荷预测。为此，国际学界相继提出一系列轻量化变体：Zhou 等人提出的 Informer 采用 ProbSparse 稀疏自注意力机制^[24]，仅保留对输出贡献最大的少量查询向量，并通过自注意力蒸馏逐层缩减序列长度，将复杂度降至对数线性级别，同时设计生成式解码器实现长序列一次性输出；Kitaev 等人提出的 Reformer 通过局部敏感哈希^[26]将相似查询聚类，大幅降低注意力计算量并支持可逆残差以节省显存。这些变体显著降低了算力开销，使长周期电力时序预测在工程上成为可能。

C0148

事实核查：部分支持

判断来源：模型知识（未作联网查实）
置信度：90%
原文第 19 页

判断理由

Informer确有ProbSparse、蒸馏和生成式解码器，Reformer采用LSH注意力与可逆残差；但复杂度为对数线性及“大幅降低”依赖具体实现和假设，表述略有夸大。

进一步从计算复杂度与建模能力的权衡视角审视上述高效变体：原始 Transformer 的自注意力复杂度为序列长度的平方量级，在配电网以较细粒度采样、回看窗口长达数日的场景下，注意力矩阵规模急剧膨胀，难以满足实时性要求；Informer 通过 ProbSparse 注意力与自注意力蒸馏将复杂度降至对数线性量级，更适合超长序列输入^[24]；Reformer 借助局部敏感哈希将相似查询聚类，并以可逆残差节省显存，在长序列训练上更具内存友好性^[26]；FEDformer 则在频域中仅保留少量主导频率分量，以频域稀疏性换取计算效率^[27]。这一系列效率改进的共同代价是对全局密集注意力的不同程度近似，可能在捕捉局部突变与非主导成分上有所损失，因而在工程应用中需结合负荷场景的波动特性审慎权衡。对本研究而言，效率优化与对称感知并不冲突：对称编码与对称感知偏置作为结构性归纳偏置，可在保持上述高效注意力机制的基础上叠加注入，从而在不显著增加复杂度的前提下提升领域适配性。

尤其值得专门辨析的是 Autoformer 与 FEDformer 两类引入“分解”与“频域”机制的模型，因为它们与本综述所强调的对称感知在表象上最易被混淆，需客观厘清其能力边界。Wu 等人提出的 Autoformer 引入序列分解架构与自相关机制^[25]，将序列显式分解为趋势项与季节项并在子序列层面挖掘周期依赖，更契合具有强周期性的能源时序；Zhou 等人提出的 FEDformer 在频域中进行注意力计算^[27]，仅保留少量主导频率分量，兼顾了计算效率与全局视野。客观而言，这两类模型确实已具备一定的周期建模与频域建模能力：Autoformer 的自相关机制能够捕捉序列在不同滞后下的相似子周期，FEDformer 的频域增强分解能够在频率维度上对主导成分进行选择性地建模，二者均显著优于仅在时域做密集注意力的原始 Transformer。

然而，从本综述所界定的对称结构视角看，二者的周期/频域机制与对称感知仍存在本质差异，并不能等价替代对称先验的注入。其一，Autoformer 的自相关刻画的是序列与其滞后版本之间的相似强度，本质上是一种关联强度度量，并不显式约束序列关于周期中点的镜像对称结构是否被保持，亦不刻画作用方向；当负荷曲线存在非对称畸变（如午间凹陷的不对称下凹）时，自相关峰值可能依旧较高，但周期镜像残差能量比 SP_per 已显著下降，二者并不等价。其二，FEDformer 的频域注意力关注的是主导频率分量的能量与相位，其优化目标并不包含高低频分量能量关于主频的互补配对均衡（即 SP_freq），因而无法保证频率互补对称结构在建模过程中被主动维持。其三，无论 Autoformer 还是 FEDformer，其分解与频域机制均作用于时序维度，对气象、日期、负荷等多类特征之间的双向关联对称（SP_corr）缺乏专门的建模通道。由

P042

AIGC / 改写倾向

分类分数 56.0%
置信度：低
原文第 20 页

判断依据

- 本段的统计贡献主要集中在“而言”、“因而”、“机制”、“复杂”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 6 句，平均每句约 70 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“而言”、“因而”、“机制”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“因而”、“进一步”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 3 组数字、3 处引文、5 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

进一步从计算复杂度与建模能力的权衡视角审视上述高效变体：原始 Transformer 的自注意力复杂度为序列长度的平方量级，在配电网以较细粒度采样、回看窗口长达数日的场景下，注意力矩阵规模急剧膨胀，难以满足实时性要求；Informer 通过 ProbSparse 注意力与自注意力蒸馏将复杂度降至对数线性量级，更适合超长序列输入^[24]；Reformer 借助局部敏感哈希将相似查询聚类，并以可逆残差节省显存，在长序列训练上更具内存友好性^[26]；FEDformer 则在频域中仅保留少量主导频率分量，以频域稀疏性换取计算效率^[27]。这一系列效率改进的共同代价是对全局密集注意力的不同程度近似，可能在捕捉局部突变与非主导成分上有所损失，因而在工程应用中需结合负荷场景的波动特性审慎权衡。对本研究而言，效率优化与对称感知并不冲突：对称编码与对称感知偏置作为结构性归纳偏置，可在保持上述高效注意力机制的基础上叠加注入，从而在不显著增加复杂度的前提下提升领域适配性。

尤其值得专门辨析的是 Autoformer 与 FEDformer 两类引入“分解”与“频域”机制的模型，因为它们与本综述所强调的对称感知在表象上最易被混淆，需客观厘清其能力边界。Wu 等人提出的 Autoformer 引入序列分解架构与自相关机制^[25]，将序列显式分解为趋势项与季节项并在子序列层面挖掘周期依赖，更契合具有强周期性的能源时序；Zhou 等人提出的 FEDformer 在频域中进行注意力计算^[27]，仅保留少量主导频率分量，兼顾了计算效率与全局视野。客观而言，这两类模型确实已具备一定的周期建模与频域建模能力：Autoformer 的自相关机制能够捕捉序列在不同滞后下的相似子周期，FEDformer 的频域增强分解能够在频率维度上对主导成分进行选择性地建模，二者均显著优于仅在时域做密集注意力的原始 Transformer。

然而，从本综述所界定的对称结构视角看，二者的周期/频域机制与对称感知仍存在本质差异，并不能等价替代对称先验的注入。其一，Autoformer 的自相关刻画的是序列与其滞后版本之间的相似强度，本质上是一种关联强度度量，并不显式约束序列关于周期中点的镜像对称结构是否被保持，亦不刻画作用方向；当负荷曲线存在非对称畸变（如午间凹陷的不对称下凹）时，自相关峰值可能依旧较高，但周期镜像残差能量比 SP_per 已显著下降，二者并不等价。其二，FEDformer 的频域注意力关注的是主导频率分量的能量与相位，其优化目标并不包含高低频分量能量关于主频的互补配对均衡（即 SP_freq），因而无法保证频率互补对称结构在建模过程中被主动维持。其三，无论 Autoformer 还是 FEDformer，其分解与频域机制均作用于时序维度，对气象、日期、负荷等多类特征之间的双向关联对称（SP_corr）缺乏专门的建模通道。由

P045

AIGC / 改写倾向

分类分数 65.0%

置信度：低

原文第 20-21 页（跨页）

判断依据

- 本段的统计贡献主要集中在“由此可见，”、“这一”、“机制”、“归纳”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 2 句，平均每句约 123 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“由此可见，”、“这一”、“机制”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“由此”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 3 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

此可见，现有周期/频域建模机制与对称感知在度量对象、作用方向与约束目标上均不重合，前者关注“关联强度与主导成分”，后者关注“镜像结构、能量配对与方向均衡”，二者正交互补而非彼此替代——这一辨析正是本综述将对称编码与对称感知偏置作为独立归纳偏置显式注入模型结构的论证基础，亦回应了“现有模型是否已隐含对称感知”这一关键质疑。

2.2.3 Crossformer 与跨维度依赖建模

针对多变量时序中特征维度间依赖建模不足的问题，Zhang 与 Yan 提出的 Crossformer 创新性地设计了维度分段嵌入 (DSW) 与两阶段注意力 (TSA) 机制^[28]，突破了传统 Transformer 仅挖掘时序维度依赖的局限，能够同时捕捉时间维度与特征维度的交叉关联，在通用多变量时序预测任务中表现优异。具体而言，DSW 嵌入将每个变量的时序序列切分为若干等长片段并嵌入为二维向量数组，既保留了时间维度的局部模式，又显式区分了不同特征维度；TSA 则先在时间维度做跨时间注意力、再在特征维度做跨维度注意力，并通过引入路由机制降低跨维度注意力的计算复杂度。这种“时间—维度”双阶段建模机制，使 Crossformer 在处理多源耦合的电力负荷数据时具备天然优势，也为在 DSW 与 TSA 两个环节分别注入时序对称编码与对称感知偏置提供了结构接口。

此外，Lai 等人提出的 LSTNet 通过卷积层与循环层的组合捕捉局部模式与长短期模式^[29]，并引入自回归分量增强对尺度变化的适应性；Bai 等人提出的时域卷积网络 (TCN) 通过因果卷积与膨胀卷积构建大感受野^[30]，验证了卷积结构在时序建模中可与循环结构相媲美；Wu 等人提出的 Graph WaveNet 将图卷积与膨胀卷积结合^[31]，从时空依赖角度建模多变量序列的拓扑关联。近年来，时序预测领域还涌现出一批不依赖复杂注意力、强调结构简洁与多尺度建模的新范式：Zeng 等人通过线性模型对比实验对 Transformer 在时序预测中的有效性提出质疑^[74]，Nie 等人提出基于片段化 (patching) 的 PatchTST 显著提升了长时序预测精度^[73]，Liu 等人提出的 iTransformer 将注意力作用于变量维度而非时间维度^[75]，Wu 等人提出的 TimesNet 将一维时序重塑为二维以建模多周期性^[77]，Wang 等人提出的 TimeMixer 通过可分解的多尺度混合实现高效预测^[76]，乃至面向时序的基础模型亦开始出现^[78]。这些工作丰富了多变量、多尺度时序建模的方法谱系，但其设计目标普遍指向通用时序预测的精度与效率，仍未将电力负荷特有的对称物理规律作为显式归纳偏置纳入模型结构。

P045

AIGC / 改写倾向

分类分数 65.0%
置信度：低
原文第 20-21 页（跨页）

判断依据

1. 本段的统计贡献主要集中在“由此可见，”、“这一”、“机制”、“归纳”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
2. 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
3. 本段可切分为 2 句，平均每句约 123 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

1. 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
2. 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
3. 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

1. 回看“由此可见，”、“这一”、“机制”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权。
2. 核对“由此”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
3. 本段包含 3 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
4. 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

需要指出的是，目前 Crossformer 在配电网短期负荷预测领域的应用案例较少，且现有应用多为通用模型的直接迁移，未结合电力负荷的对称时序规律进行定制化改造，其捕捉跨维度依赖的能力尚未被引导用于刻画负荷的对称耦合关系——这恰是本综述将对称感知机理嵌入 Crossformer 的根本动因。

进一步剖析 Crossformer 应用于电力负荷预测的适配性可知，其 DSW 嵌入将时序切分为等长片段的设计，与负荷以日为基本节律单元的物理特性高度契合，为在嵌入层注入以日、周为周期的对称编码提供了天然的结构接口；其 TSA 机制先在时间维度、再在特征维度施加注意力的两阶段设计，则为在跨维度注意力中引入对称关联感知偏置提供了可作用的位置。然而，标准 Crossformer 的两阶段注意力完全依赖数据驱动学习维度间的统计关联，当训练样本中极端工况占比偏低时，模型难以从有限样本中自发学到稳定的对称耦合规律，这正是通用模型在小样本、强波动场景下泛化性能受限的深层原因。引入对称关联先验作为注意力偏置，相当于为模型提供了一条无需从数据中重新学习、可直接利用的领域知识捷径，有助于在样本受限条件下提升模型对对称耦合关系的刻画能力，这一思路与几何深度学习中以归纳偏置压缩假设空间的理念一致。

2.2.4 国内模型融合与轻量化研究

国内研究在深度时序预测方向以模型融合为主要思路，将 Transformer 及其变体与卷积神经网络、时域卷积网络、图神经网络相结合，分别挖掘局部时序特征、空间拓扑特征与全局依赖特征，以兼顾不同尺度的预测需求^[32]。这类融合模型的设计哲学在于：不同网络结构具有互补的特征提取能力，卷积网络擅长捕捉局部突变模式，图神经网络擅长刻画节点间的空间拓扑关系，而注意力机制擅长建模全局长程依赖，通过有机组合可实现优势互补。王健等人系统研究了 Transformer 及其变体在电力时序预测中的应用与改进^[32]，对比分析了不同注意力机制在负荷预测任务中的适配性。

同时，面向边缘终端部署需求，国内学者广泛开展模型轻量化、剪枝与量化研究，通过结构化剪枝去除冗余通道、通过低比特量化压缩模型存储^[33, 34]，在保证精度损失可控的前提下显著降低模型推理的算力与存储开销，推动深度预测模型在配电网台区边缘侧的实际落地。整体而言，国内学者已充分意识到多特征关联对负荷预测的重要性，但主流研究仍聚焦于线性、非线性关联与时序依赖建模，针对特征间对称关联的感知与建模研究尚不充分。

P049

AIGC / 改写倾向

分类分数 54.0%
置信度：低
原文第 22 页

判断依据

- 本段的统计贡献主要集中在“然而”、“应用于”、“条件下”、“有助于”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 4 句，平均每句约 95 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“然而”、“应用于”、“条件下”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“然而”、“进一步”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 4 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

进一步从模型融合的内在机理审视国内研究的技术路线可知，其融合策略大体可归纳为串联式、并联式与嵌入式三类：串联式融合将不同网络按数据流依次级联，前级网络的输出作为后级网络的输入，典型如先以卷积网络提取局部特征、再以注意力网络挖掘全局依赖，其优势在于结构清晰、易于实现，但存在误差逐级传递与累积的风险；并联式融合则令多个网络分支并行处理同一输入，再通过加权、拼接或注意力门控融合各分支输出，能够兼顾多尺度、多视角特征，但融合权重的确定往往依赖经验或额外的训练开销；嵌入式融合则将一类网络的算子直接嵌入另一类网络的内部结构，如在 Transformer 的前馈层中嵌入卷积算子以增强局部建模能力，融合程度最深但设计复杂度也最高^[32, 33]。这三类融合策略虽在工程上各有所长，却普遍停留在网络结构的算子级组合层面，缺乏面向电力负荷物理规律的统一设计主线，融合所得模型本质上仍是数据驱动的统计拟合器，未能将负荷的对称物理先验作为贯穿融合过程的内核，这正是国内融合研究在领域适配深度上的共性局限，也凸显了以对称先验统摄模型结构设计的必要性。

2.2.5 国内外对比、文献计量与细分空白

在深度时序预测方向，国际研究主导了基础架构与高效注意力机制的理论创新，从 Transformer 到 Informer、Autoformer、FEDformer、Crossformer 乃至 PatchTST、iTransformer 等的演进，构建了完整的模型谱系；国内研究则在多模型融合、工程轻量化与场景适配方面贡献突出。从文献时间分布看，本分支文献高度集中于 2017 年后，并在 2021—2024 年间呈现注意力高效化与跨维度、多尺度建模并行推进的活跃态势；从来源分布看，基础架构创新多见于人工智能与机器学习领域顶级会议，工程化与场景适配研究多见于电力系统领域期刊及国内学位论文，体现出“顶会奠基、期刊落地”的典型分工。

然而，无论国际还是国内，现有深度模型在电力负荷这一特定领域均存在结构性缺陷：其一，模型核心聚焦于时序维度的依赖挖掘，对气象、日期、负荷等多类特征之间的对称耦合关联建模能力薄弱，难以刻画影响因素与负荷之间的协同对称关系；其二，标准 Crossformer 等模型未嵌入对称感知机理，无法适配电力负荷特有的周期对称规律，领域适配性不足、泛化性能受限；其三，两阶段注意力等机制存在冗余计算，在结合多分量分解数据后推理效率进一步下降，难以同时满足高精度与实时性的双重要求。这表明，将对称先验作为显式归纳偏置注入深度模型结构，是提升其领域

P053

AIGC / 改写倾向

分类分数 54.0%
置信度：低
原文第 23 页

判断依据

- 本段的统计贡献主要集中在“集中于”、“并在”、“突出。”、“推进的”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 4 句，平均每句约 76 字；低权重辅助统计分别略偏向自然差异和轻度整理，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“集中于”、“并在”、“突出。”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段包含 3 组数字、7 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

进一步从模型融合的内在机理审视国内研究的技术路线可知，其融合策略大体可归纳为串联式、并联式与嵌入式三类：串联式融合将不同网络按数据流依次级联，前级网络的输出作为后级网络的输入，典型如先以卷积网络提取局部特征、再以注意力网络挖掘全局依赖，其优势在于结构清晰、易于实现，但存在误差逐级传递与累积的风险；并联式融合则令多个网络分支并行处理同一输入，再通过加权、拼接或注意力门控融合各分支输出，能够兼顾多尺度、多视角特征，但融合权重的确定往往依赖经验或额外的训练开销；嵌入式融合则将一类网络的算子直接嵌入另一类网络的内部结构，如在 Transformer 的前馈层中嵌入卷积算子以增强局部建模能力，融合程度最深但设计复杂度也最高^[32, 33]。这三类融合策略虽在工程上各有所长，却普遍停留在网络结构的算子级组合层面，缺乏面向电力负荷物理规律的统一设计主线，融合所得模型本质上仍是数据驱动的统计拟合器，未能将负荷的对称物理先验作为贯穿融合过程的内核，这正是国内融合研究在领域适配深度上的共性局限，也凸显了以对称先验统摄模型结构设计的必要性。

2.2.5 国内外对比、文献计量与细分空白

在深度时序预测方向，国际研究主导了基础架构与高效注意力机制的理论创新，从 Transformer 到 Informer、Autoformer、FEDformer、Crossformer 乃至 PatchTST、iTransformer 等的演进，构建了完整的模型谱系；国内研究则在多模型融合、工程轻量化与场景适配方面贡献突出。从文献时间分布看，本分支文献高度集中于 2017 年以后，并在 2021—2024 年间呈现注意力高效化与跨维度、多尺度建模并行推进的活跃态势；从来源分布看，基础架构创新多见于人工智能与机器学习领域顶级会议，工程化与场景适配研究多见于电力系统领域期刊及国内学位论文，体现出“顶会奠基、期刊落地”的典型分工。

然而，无论国际还是国内，现有深度模型在电力负荷这一特定领域均存在结构性缺陷：其一，模型核心聚焦于时序维度的依赖挖掘，对气象、日期、负荷等多类特征之间的对称耦合关联建模能力薄弱，难以刻画影响因素与负荷之间的协同对称关系；其二，标准 Crossformer 等模型未嵌入对称感知机理，无法适配电力负荷特有的周期对称规律，领域适配性不足、泛化性能受限；其三，两阶段注意力等机制存在冗余计算，在结合多分量分解数据后推理效率进一步下降，难以同时满足高精度与实时性的双重要求。这表明，将对称先验作为显式归纳偏置注入深度模型结构，是提升其领域

P054

AIGC / 改写倾向

分类分数 70.0%
置信度：低
原文第 23 页

判断依据

- 本段的统计贡献主要集中在“然而”、“之间的”、“这一”、“核心”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 1 句，平均每句约 108 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。

复核建议

- 回看“然而”、“之间的”、“这一”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“然而”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

进一步从模型融合的内在机理审视国内研究的技术路线可知，其融合策略大体可归纳为串联式、并联式与嵌入式三类：串联式融合将不同网络按数据流依次级联，前级网络的输出作为后级网络的输入，典型如先以卷积网络提取局部特征、再以注意力网络挖掘全局依赖，其优势在于结构清晰、易于实现，但存在误差逐级传递与累积的风险；并联式融合则令多个网络分支并行处理同一输入，再通过加权、拼接或注意力门控融合各分支输出，能够兼顾多尺度、多视角特征，但融合权重的确定往往依赖经验或额外的训练开销；嵌入式融合则将一类网络的算子直接嵌入另一类网络的内部结构，如在 Transformer 的前馈层中嵌入卷积算子以增强局部建模能力，融合程度最深但设计复杂度也最高^[32, 33]。这三类融合策略虽在工程上各有所长，却普遍停留在网络结构的算子级组合层面，缺乏面向电力负荷物理规律的统一设计主线，融合所得模型本质上仍是数据驱动的统计拟合器，未能将负荷的对称物理先验作为贯穿融合过程的内核，这正是国内融合研究在领域适配深度上的共性局限，也凸显了以对称先验统摄模型结构设计的必要性。

2.2.5 国内外对比、文献计量与细分空白

在深度时序预测方向，国际研究主导了基础架构与高效注意力机制的理论创新，从 Transformer 到 Informer、Autoformer、FEDformer、Crossformer 乃至 PatchTST、iTransformer 等的演进，构建了完整的模型谱系；国内研究则在多模型融合、工程轻量化与场景适配方面贡献突出。从文献时间分布看，本分支文献高度集中于 2017 年以后，并在 2021—2024 年间呈现注意力高效化与跨维度、多尺度建模并行推进的活跃态势；从来源分布看，基础架构创新多见于人工智能与机器学习领域顶级会议，工程化与场景适配研究多见于电力系统领域期刊及国内学位论文，体现出“顶会奠基、期刊落地”的典型分工。

然而，无论国际还是国内，现有深度模型在电力负荷这一特定领域均存在结构性缺陷：其一，模型核心聚焦于时序维度的依赖挖掘，对气象、日期、负荷等多类特征之间的对称耦合关联建模能力薄弱，难以刻画影响因素与负荷之间的协同对称关系；其二，标准 Crossformer 等模型未嵌入对称感知机理，无法适配电力负荷特有的周期对称规律，领域适配性不足、泛化性能受限；其三，两阶段注意力等机制存在冗余计算，在结合多分量分解数据后推理效率进一步下降，难以同时满足高精度与实时性的双重要求。这表明，将对称先验作为显式归纳偏置注入深度模型结构，是提升其领域

P055

AIGC / 改写倾向

分类分数 60.0%
置信度：低
原文第 23-24 页（跨页）

判断依据

- 本段的统计贡献主要集中在“表明”、“难以”、“据此”、“机制”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 4 句，平均每句约 61 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“表明”、“难以”、“据此”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“同时”、“进一步”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 4 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

适配性的关键突破口。本综述据此在 DSW 嵌入层注入时序对称编码、在 TSA 注意力中增设对称关联感知偏置，并面向不同对称特性的 IMF 分量配置差异化网络，从模型结构层面实现对负荷对称规律的主动适配。

2.3 特征关联分析与元启发式智能优化算法研究现状

负荷演化是多因子耦合作用的结果。特征关联分析用于从众多影响因子中筛选有效特征、剔除冗余信息，而元启发式智能优化算法则主要用于模态分解参数与深度学习超参数的全局寻优。二者是提升混合预测框架性能的两大核心辅助模块，其研究水平直接影响预测精度的上限：前者决定了模型输入信息的质量与精炼程度，后者决定了模型与分解算法能否逼近其性能上界，二者协同作用于整个预测框架的精度与鲁棒性。

2.3.1 特征关联分析方法研究

在特征关联量化方面，国内外常用皮尔逊相关系数、斯皮尔曼等级相关、互信息（Mutual Information, MI）、最大信息系数（Maximal Information Coefficient, MIC）等方法度量特征与负荷之间的关联程度^[35, 36, 37]。其中，皮尔逊系数仅能刻画线性关联，对非线性关系的识别能力有限；斯皮尔曼相关适用于单调非线性关系，但对非单调关联同样失效；互信息能够度量任意形式的统计依赖，但其估计依赖于概率密度的准确估计，在小样本与高维场景下存在较大偏差；而 MIC 因其能够捕捉任意函数形式的关联并具备良好的均匀性与对称性，在负荷影响因子分析中应用广泛。MIC 的核心思想是：对两变量构成的散点图施加不同的网格划分，计算各划分下的归一化互信息并取最大值，从而度量变量间最强的函数依赖关系^[36]。为解决 MIC 在高维数据上计算开销大的问题，Tang 等人提出 RapidMIC 实现了 MIC 的快速计算^[38]，通过优化网格搜索策略大幅降低了计算复杂度；在此基础上发展出的多元快速最大信息系数（MVRapidMIC）兼顾了多元变量关联分析能力与计算效率，特别适用于高维电力特征筛选。

然而，当前主流方案仍以离线静态特征筛选为主，即基于全量数据集计算全局关联系数完成特征初选。这种静态策略忽视了电力负荷与影响因子关联强度的时变特性——在极端气象、临时节假日等场景下会出现短时强关联特征，静态筛选容易遗漏此类动态关联信息；同时，现有关联分析未结合特征间的对称映射规律开展定向筛

P055

AIGC / 改写倾向

分类分数 60.0%
置信度：低
原文第 23-24 页（跨页）

判断依据

- 本段的统计贡献主要集中在“表明”、“难以”、“据此”、“机制”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 4 句，平均每句约 61 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“表明”、“难以”、“据此”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“同时”、“进一步”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 4 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

选，难以为对称感知建模提供高质量的特征对称先验。从文献分布看，特征关联分析方法的奠基性成果集中于统计学与信息论领域经典文献，而在电力负荷领域的应用研究则相对零散、缺乏面向动态时变关联与方向对称的系统综述，构成本分支的一处明显细分空白。本综述提出的双向 MVRapidMIC 关联对称度分析方法，正是针对这两点不足而设计：通过构造因子与负荷之间的双向最大信息系数并定义关联对称度 SP_corr ，既识别强关联又刻画信息传递的方向均衡性，从而为对称感知建模提供方向化、对称化的特征先验。

从关联度量方法的能力边界看，皮尔逊相关、互信息与最大信息系数虽各有所长，却均未触及关联的方向性这一维度。皮尔逊相关本身是对称的，即因子对负荷与负荷对因子的相关系数完全相等，因而无法刻画双向信息传递的不对称；互信息同样是对称泛函，其值不区分作用方向；最大信息系数虽能捕捉任意函数形式的关联，但在标准定义下亦不区分方向。然而，在电力负荷场景中，气象因子对负荷的影响与负荷对气象因子的反向可预测性在信息量上未必相等——例如温度对负荷具有明确的物理驱动作用，而负荷对温度的反向信息则相对有限。正是这种方向上的不对称，蕴含着区分“强驱动核心因子”与“弱驱动伴随因子”的重要线索。本综述构造的双向最大信息系数恰恰能够捕捉这一方向差异，并以关联对称度 SP_corr 加以量化，从而在传统强度筛选之外补充了方向对称这一全新的筛选维度，这是对现有静态、单向关联分析范式的实质性拓展。

2.3.2 元启发式智能优化算法研究

元启发式智能优化算法是模态分解参数与深度模型超参数自适应寻优的核心工具。Holland 提出的遗传算法（Genetic Algorithm, GA）^[39]通过模拟生物进化的选择、交叉、变异操作搜索最优解，奠定了进化计算的基础；Kennedy 与 Eberhart 提出的粒子群优化（Particle Swarm Optimization, PSO）^[40]通过模拟鸟群觅食行为，利用个体最优与全局最优引导粒子在解空间中飞行，以其实现简单、收敛快速的特点被广泛应用。此后，Xue 与 Shen 提出的麻雀搜索算法（Sparrow Search Algorithm, SSA）^[41]模拟麻雀的觅食与反捕食行为，通过发现者—加入者—预警者的角色分工平衡探索与开发；Mirjalili 等人提出的灰狼优化（Grey Wolf Optimizer, GWO）^[42]模拟灰狼群体的社会等级与围猎机制，鲸鱼优化算法（Whale Optimization Algorithm, WOA）模拟座头

鲸的气泡网捕食策略^[43]，这些新型算法不断涌现，被广泛应用于 MVMD 与深度学习模型的参数寻优。

然而，这些经典算法普遍存在后期收敛速度慢、高维空间易陷入局部最优、种群多样性衰退等问题，在复杂非平稳的实际负荷场景中难以保证寻优的稳定性与最优性。Suyanto 等人于 2022 年提出的科莫多龙优化算法（KMA）是一种新型元启发式算法^[44]，它模拟科莫多巨蜥的种群分层与觅食行为，将种群划分为大型、中型、小型三类个体并赋予差异化的移动与繁殖规则，融合了遗传算法与粒子群算法的优势，通过种群分层演化机制平衡全局探索与局部开发能力，在高维优化场景中展现出一定潜力。但原始 KMA 在复杂非平稳工程场景中仍存在种群分布不均、迭代后期寻优停滞等缺陷，亟需结合混沌动力学、自适应权重等策略进行算法增强。各类智能优化算法的寻优性能对比如图所示。




图 7 元启发式智能优化算法寻优性能对比图

2.3.3 混沌策略与算法增强研究

为克服群智能算法的早熟收敛与局部最优问题，将混沌动力学引入优化过程已成为重要研究方向。混沌映射具备遍历性、随机性与规律性兼备的特点，能够在保证遍历整个搜索空间的同时避免完全随机带来的盲目性，因而能够提升种群初始化的空间均匀性并增强局部最优逃逸能力。常用的混沌映射包括 Logistic 映射、Tent 映射、Chebyshev 映射、Circle 映射等，其中 Logistic 映射结构简单、遍历性好，常用于种群初始化；Tent 映射分布更为均匀、迭代速度快，常用于局部扰动^[46]。陈哲针对模态分解参数优化问题，系统研究了群智能优化算法在负荷预测中的应用^[45]，验证了智能优

化对分解质量的提升作用；黄传金等人将混沌映射引入粒子群算法^[46]，通过混沌初始化与混沌扰动显著改善了其收敛性能与全局搜索能力；Gao 等人提出基于混沌局部搜索的差分进化算法^[47]，进一步验证了混沌策略对优化性能的增益。这些研究为通过 Logistic 混沌映射初始化、非线性时变惯性权重与 Tent 混沌扰动等多重策略对 KMA 进行系统增强、构建兼顾分解精度、模态正交性与计算效率的多目标优化引擎提供了方法学支撑。

从混沌增强策略的作用机理看，不同混沌映射在优化的不同阶段承担差异化功能：种群初始化阶段引入 Logistic 映射，可借助其良好的遍历性使初始个体在解空间中分布更为均匀，避免随机初始化可能造成的初始种群聚集，从而为全局探索奠定基础；迭代寻优阶段引入非线性时变惯性权重，可在前期保持较强的全局探索能力、后期增强局部开发能力，平衡探索与开发的矛盾；局部扰动阶段引入 Tent 映射，则可在算法陷入局部最优时以混沌扰动激活种群多样性，提升跳出局部最优的概率。三类策略协同作用，针对原始 KMA 种群分布不均、迭代后期寻优停滞的缺陷形成系统性补强。需要说明的是，混沌增强策略的有效性在差分进化、粒子群等多种算法上已得到验证^[46, 47]，但将其系统性地用于 KMA 并面向模态分解参数与对称保真目标的联合寻优，仍是一处值得深入开展的研究方向。

2.3.4 国内外对比、文献计量与细分空白

在特征关联分析与智能优化方向，国际研究在 MIC、互信息等关联度量与 GA、PSO、GWO、KMA 等优化算法的原始创新方面占据主导，奠定了方法学基础；国内研究则在关联分析的工程化应用、混沌增强等算法改进策略与电力场景适配方面更为活跃。从文献时间分布看，关联度量方法的奠基性文献跨度较长（自 19 世纪末的皮尔逊相关至 2014 年的 RapidMIC），而群智能优化算法则自 1995 年的 PSO 以来持续涌现，并在 2020 年前后迎来 SSA、KMA 等新型算法的密集提出；从来源分布看，算法原始创新多见于工程软件、软计算与系统科学领域国际期刊，混沌增强与电力适配研究多见于国内控制与电力期刊。

然而，两类研究仍存在共性不足：在特征关联方面，静态离线筛选难以捕捉关联强度的时变特性，且未结合特征对称映射规律开展定向筛选；在智能优化方面，经典算法在高维、强噪声场景下的寻优稳定性不足，新型 KMA 算法的工程适配性增强仍有较大空间，且优化目标多为单一精度指标，未将对称保真度纳入适应度函数设计。

P065

AIGC / 改写倾向

分类分数 75.0%
置信度：低
原文第 27 页

判断依据

- 本段的统计贡献主要集中在“然而”、“仍存在”、“不足”、“增强”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 2 句，平均每句约 72 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“然而”、“仍存在”、“不足”，“附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“然而”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 1 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。

这两方面的不足，限制了特征筛选质量与分解参数寻优精度，进而制约了整体预测框架性能的提升。本综述针对性地构建混沌增强 EnKMA 算法，并将对称保真度 SF 显式纳入多目标适应度函数，使智能优化模块与对称约束分解、对称感知建模在优化目标层面实现统一。

2.4 物理信息嵌入与概率化预测的前沿进展

除上述三大主线之外，近年来两类与本研究密切相关的前沿方向正快速兴起，对“对称先验作为物理归纳偏置”这一核心思想构成重要的方法学呼应与补充，有必要纳入现状评述以完整刻画领域格局。

2.4.1 物理信息神经网络与领域知识嵌入

物理信息神经网络（Physics-Informed Neural Network, PINN）由 Raissi 等人系统提出^[82]，其核心思想是将描述系统行为的物理定律（通常以偏微分方程或守恒约束的形式）作为软约束嵌入神经网络的损失函数，使模型在拟合观测数据的同时满足已知物理规律，从而显著提升模型在小样本与外推场景下的泛化能力与可解释性。Karniadakis 等人进一步将这一思想凝练为“物理信息机器学习”的统一范式，指出将领域先验以约束、结构或数据增强等多种形式注入学习过程，是连接数据驱动与机理驱动的关键桥梁^[83]。在电力系统领域，已有研究系统综述了 PINN 在潮流计算、状态估计、动态建模等任务中的应用进展，验证了物理约束对提升电力系统智能模型可信度的价值^[84]。

PINN 范式与本研究存在深刻的方法学共鸣：本综述所提出的对称保真约束，本质上正是一种以负荷物理对称规律为内容的“软物理约束”——它不要求严格满足对称等式，而是以惩罚项形式引导分解与建模过程保持负荷固有的对称结构，与 PINN 将物理定律作为可微软约束的思想一脉相承。区别在于，PINN 通常嵌入的是显式的微分方程约束，而本综述嵌入的是以统计镜像近似不变性为内容的对称结构约束，更契合负荷这类缺乏精确解析方程、却具有稳定统计规律的工程时序。这一对照不仅为本研究的对称约束建模提供了方法学合法性支撑，也表明将对称先验前置为主动约束符合“物理信息嵌入智能建模”的总体趋势。

2.4.2 对称性与等变性归纳偏置研究

P066

AIGC / 改写倾向

分类分数 63.0%
置信度：低
原文第 28 页

判断依据

- 本段的统计贡献主要集中在“进而”、“并将”、“针对性”、“不足，”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 2 句，平均每句约 59 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“进而”、“并将”、“针对性”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段包含 2 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

这两方面的不足，限制了特征筛选质量与分解参数寻优精度，进而制约了整体预测框架性能的提升。本综述针对性地构建混沌增强 EnKMA 算法，并将对称保真度 SF 显式纳入多目标适应度函数，使智能优化模块与对称约束分解、对称感知建模在优化目标层面实现统一。

2.4 物理信息嵌入与概率化预测的前沿进展

除上述三大主线之外，近年来两类与本研究密切相关的前沿方向正快速兴起，对“对称先验作为物理归纳偏置”这一核心思想构成重要的方法学呼应与补充，有必要纳入现状评述以完整刻画领域格局。

2.4.1 物理信息神经网络与领域知识嵌入

物理信息神经网络（Physics-Informed Neural Network, PINN）由 Raissi 等人系统提出^[82]，其核心思想是将描述系统行为的物理定律（通常以偏微分方程或守恒约束的形式）作为软约束嵌入神经网络的损失函数，使模型在拟合观测数据的同时满足已知物理规律，从而显著提升模型在小样本与外推场景下的泛化能力与可解释性。Karniadakis 等人进一步将这一思想凝练为“物理信息机器学习”的统一范式，指出将领域先验以约束、结构或数据增强等多种形式注入学习过程，是连接数据驱动与机理驱动的关键桥梁^[83]。在电力系统领域，已有研究系统综述了 PINN 在潮流计算、状态估计、动态建模等任务中的应用进展，验证了物理约束对提升电力系统智能模型可信度的价值^[84]。

PINN 范式与本研究存在深刻的方法学共鸣：本综述所提出的对称保真约束，本质上正是一种以负荷物理对称规律为内容的“软物理约束”——它不要求严格满足对称等式，而是以惩罚项形式引导分解与建模过程保持负荷固有的对称结构，与 PINN 将物理定律作为可微约束的思想一脉相承。区别在于，PINN 通常嵌入的是显式的微分方程约束，而本综述嵌入的是以统计镜像近似不变性为内容的对称结构约束，更契合负荷这类缺乏精确解析方程、却具有稳定统计规律的工程时序。这一对照不仅为本研究的对称约束建模提供了方法学合法性支撑，也表明将对称先验前置为主动约束符合“物理信息嵌入智能建模”的总体趋势。

2.4.2 对称性与等变性归纳偏置研究

P067

AIGC / 改写倾向

分类分数 51.0%

置信度：低

原文第 28 页

判断依据

- 本段的统计贡献主要集中在“密切相关”、“有必要”、“这一”、“归纳”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 1 句，平均每句约 87 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 本段只有约 88 个有效字符，可观察到的局部模式较少，分类稳定性有限。

复核建议

- 回看“密切相关”、“有必要”、“这一”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

这两方面的不足，限制了特征筛选质量与分解参数寻优精度，进而制约了整体预测框架性能的提升。本综述针对性地构建混沌增强 EnKMA 算法，并将对称保真度 SF 显式纳入多目标适应度函数，使智能优化模块与对称约束分解、对称感知建模在优化目标层面实现统一。

2.4 物理信息嵌入与概率化预测的前沿进展

除上述三大主线之外，近年来两类与本研究密切相关的前沿方向正快速兴起，对“对称先验作为物理归纳偏置”这一核心思想构成重要的方法学呼应与补充，有必要纳入现状评述以完整刻画领域格局。

2.4.1 物理信息神经网络与领域知识嵌入

物理信息神经网络（Physics-Informed Neural Network, PINN）由 Raissi 等人系统提出^[82]，其核心思想是将描述系统行为的物理定律（通常以偏微分方程或守恒约束的形式）作为软约束嵌入神经网络的损失函数，使模型在拟合观测数据的同时满足已知物理规律，从而显著提升模型在小样本与外推场景下的泛化能力与可解释性。Karniadakis 等人进一步将这一思想凝练为“物理信息机器学习”的统一范式，指出将领域先验以约束、结构或数据增强等多种形式注入学习过程，是连接数据驱动与机理驱动的关键桥梁^[83]。在电力系统领域，已有研究系统综述了 PINN 在潮流计算、状态估计、动态建模等任务中的应用进展，验证了物理约束对提升电力系统智能模型可信度的价值^[84]。

PINN 范式与本研究存在深刻的方法学共鸣：本综述所提出的对称保真约束，本质上正是一种以负荷物理对称规律为内容的“软物理约束”——它不要求严格满足对称等式，而是以惩罚项形式引导分解与建模过程保持负荷固有的对称结构，与 PINN 将物理定律作为可微约束的思想一脉相承。区别在于，PINN 通常嵌入的是显式的微分方程约束，而本综述嵌入的是以统计镜像近似不变性为内容的对称结构约束，更契合负荷这类缺乏精确解析方程、却具有稳定统计规律的工程时序。这一对照不仅为本研究的对称约束建模提供了方法学合法性支撑，也表明将对称先验前置为主动约束符合“物理信息嵌入智能建模”的总体趋势。

2.4.2 对称性与等变性归纳偏置研究

P068

AIGC / 改写倾向

分类分数 52.0%
置信度：低
原文第 28 页

判断依据

- 本段的统计贡献主要集中在“而显著提升模”、“其核心”、“约束”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 联合统计结果靠近相邻分类边界，当前结论对少量措辞变化较敏感，应优先人工复核。
- 本段可切分为 1 句，平均每句约 165 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“而显著提升模”、“其核心”、“约束”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“同时”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 1 组数字、1 处引文、5 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

这两方面的不足，限制了特征筛选质量与分解参数寻优精度，进而制约了整体预测框架性能的提升。本综述针对性地构建混沌增强 EnKMA 算法，并将对称保真度 SF 显式纳入多目标适应度函数，使智能优化模块与对称约束分解、对称感知建模在优化目标层面实现统一。

2.4 物理信息嵌入与概率化预测的前沿进展

除上述三大主线之外，近年来两类与本研究密切相关的前沿方向正快速兴起，对“对称先验作为物理归纳偏置”这一核心思想构成重要的方法学呼应与补充，有必要纳入现状评述以完整刻画领域格局。

2.4.1 物理信息神经网络与领域知识嵌入

物理信息神经网络（Physics-Informed Neural Network, PINN）由 Raissi 等人系统提出^[82]，其核心思想是将描述系统行为的物理定律（通常以偏微分方程或守恒约束的形式）作为软约束嵌入神经网络的损失函数，使模型在拟合观测数据的同时满足已知物理规律，从而显著提升模型在小样本与外推场景下的泛化能力与可解释性。Karniadakis 等人进一步将这一思想凝练为“物理信息机器学习”的统一范式，指出将领域先验以约束、结构或数据增强等多种形式注入学习过程，是连接数据驱动与机理驱动的关键桥梁^[83]。在电力系统领域，已有研究系统综述了 PINN 在潮流计算、状态估计、动态建模等任务中的应用进展，验证了物理约束对提升电力系统智能模型可信度的价值^[84]。

PINN 范式与本研究存在深刻的方法学共鸣：本综述所提出的对称保真约束，本质上正是一种以负荷物理对称规律为内容的“软物理约束”——它不要求严格满足对称等式，而是以惩罚项形式引导分解与建模过程保持负荷固有的对称结构，与 PINN 将物理定律作为可微约束的思想一脉相承。区别在于，PINN 通常嵌入的是显式的微分方程约束，而本综述嵌入的是以统计镜像近似不变性为内容的对称结构约束，更契合负荷这类缺乏精确解析方程、却具有稳定统计规律的工程时序。这一对照不仅为本研究的对称约束建模提供了方法学合法性支撑，也表明将对称先验前置为主动约束符合“物理信息嵌入智能建模”的总体趋势。

2.4.2 对称性与等变性归纳偏置研究

C0222

事实核查：部分支持

判断来源：模型知识（未作联网查实）
置信度：90%
原文第 28 页

判断理由

Raissi 等人系统化提出 PINN 及将物理方程残差加入损失函数的定义基本正确；但在小样本和外推中“显著提升”泛化能力、可解释性并非普遍保证，取决于物理模型和任务。

在机器学习理论层面，将对称性作为显式归纳偏置已被证明能够有效压缩假设空间、降低模型对数据量的依赖。Cohen 与 Welling 提出的群等变卷积网络^[85]通过在网络结构中显式编码对称群的等变性，使模型在旋转、平移等变换下保持可预测的输出变化，开创了等变深度学习的研究方向；Bronstein 等人提出的几何深度学习框架^[86]进一步将平移不变性、等变性等几何先验统一为深度模型设计的核心原则，系统论证了对称性归纳偏置在提升泛化能力与样本效率上的普适价值。Han 等人在视觉 Transformer 综述中亦指出，恰当的归纳偏置注入是提升 Transformer 在特定领域适配性的关键^[33]。

上述理论为本综述将对称性作为负荷预测的核心先验提供了坚实的理论依据。从物理本质看，电力负荷的对称性根植于人类社会活动的节律性与稳定性：以日、周、年为周期的作息与生产规律使负荷序列在时域上呈现稳定的周期镜像对称，高低频成分之间的能量配对关系使其在频域上呈现互补对称，气象、日期等外部因子与负荷之间稳定的双向影响关系使其在特征关联上呈现方向对称。将这三类对称性作为显式归纳偏置注入分解与建模过程，能够在不要求严格对称成立的前提下压缩假设空间、提升小样本与极端工况下的泛化能力——这一原理已在视觉领域的平移不变性、等变性研究中得到充分验证，将其迁移至负荷预测，正是本研究在方法学上的核心立足点。

2.4.3 概率化与不确定性负荷预测

随着高比例分布式电源接入带来的强随机性，负荷预测正由确定性点预测向概率化、区间化预测演进，以更好地刻画并量化预测不确定性，支撑调度决策的风险评估。Hong 等人在概率电力负荷预测的综述与全球能源预测竞赛中系统梳理了概率预测的指标体系与方法范式^[4, 58]；Salinas 等人提出的 DeepAR 基于自回归循环网络输出预测分布的参数，实现了大规模时序的概率预测^[80]；Wang 等人提出基于 Pinball 损失引导的 LSTM 实现个体负荷的概率预测^[81]；Rasul 等人将去噪扩散概率模型引入多变量时序的概率预测，进一步丰富了不确定性建模的工具箱^[79]。

概率化预测的兴起对本研究具有双重意义：一方面，它表明负荷预测领域正日益重视对随机性与不确定性的显式刻画，而本综述所强调的对称结构正是负荷在强随机扰动下仍稳定保持的确定性骨架，二者并不矛盾——对称先验刻画规律性骨架，概率化建模刻画围绕骨架的随机波动，二者结合有望进一步提升预测的稳健性与可信度；另一方面，现有概率预测研究普遍未将对称物理先验纳入分布建模，如何在保持对称

P074

AIGC / 改写倾向

分类分数 60.0%
置信度：低
原文第 29 页

判断依据

1. 本段的统计贡献主要集中在“日益”、“围绕”、“进一步”、“一方面”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
2. 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
3. 本段可切分为 1 句，平均每句约 145 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

1. 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
2. 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。

复核建议

1. 回看“日益”、“围绕”、“进一步”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
2. 核对“进一步”、“一方面”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
3. 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

结构的前提下输出对称感知的概率预测，构成一处值得后续延伸的细分空白。本综述以确定性对称感知预测框架为主体，概率化拓展则可作为未来工作的自然延伸方向。

综观本节所评述的两类前沿方向可见，物理信息嵌入与对称性归纳偏置研究为本研究提供了坚实的方法学合法性与理论支撑，表明以对称物理先验作为主动约束注入预测全流程符合机器学习与领域建模相融合的总体趋势；概率化预测研究则揭示了对称先验与不确定性建模相结合的潜在拓展空间。这两类前沿与前述三大技术主线共同勾勒出领域的完整格局：技术主线提供了分解、建模、关联、优化的具体方法工具，前沿方向则指明了将领域物理知识系统化注入这些工具的范式方向。本研究正是在这一格局中找到自身定位——以对称先验为内核，将分散在各技术分支中的方法工具按统一主线重新组织，从而回应领域对物理可解释、领域适配的混合预测框架的迫切需求。

综合本章对时序模态分解、Transformer 类深度时序预测、特征关联分析与元启发式智能优化三大主线，以及物理信息嵌入、概率化预测两类前沿方向的系统评述可见：现有研究在各自的技术维度上均已取得长足进展，形成了较为成熟的方法体系，但从配电网短期负荷预测这一特定应用场景出发，普遍缺乏一条以对称物理先验为内核、贯穿全链路的统一主线。下一章将在此基础上凝练共性问题、研判发展趋势，并给出研究现状分析结论与本研究的切入点。

3 研究现状总结与分析

通过对时序模态分解、Transformer 类深度时序预测模型、特征关联分析与元启发式智能优化算法四大技术分支，以及物理信息嵌入、概率化预测两类前沿方向国内外研究现状的系统梳理与对比，可以发现：现有研究在各自的技术维度上均已取得长足进展，形成了较为成熟的方法体系，但从配电网短期负荷预测这一特定应用场景出发，仍存在若干贯穿全链路的结构性缺陷^[2, 6]。本章首先凝练现有研究在本课题方向上存在的核心问题，继而研判该领域的未来发展趋势，最后给出研究现状分析结论，明确本研究的切入点与创新逻辑。

3.1 论文研究领域存在的问题

综合前述国内外研究现状的对比分析，当前配电网短期负荷预测研究在方法论层面存在三大共性问题，且三者之间并非孤立存在，而是以“对称特征作为统一主线的缺失”为核心症结彼此关联、层层传导，最终共同制约了混合预测框架整体性能的进一步突破。三大共性问题及其内在关联如图 7 所示。

需要强调三者之间的因果传导关系：模态分解环节的对称约束缺失是问题链条的源头，它在信号处理最前端即造成对称特征的不可逆损耗，使得进入下游的分量本身已是失真表征；深度建模环节的对称感知缺位则在中游进一步放大了这一缺陷，由于模型缺乏针对对称结构的归纳偏置，既无法从失真分量中恢复对称信息，也无法主动利用残存的对称规律；系统协同环节的优化目标割裂则在全局层面固化了前两个问题，由于缺乏一条贯穿始终的统一主线，各模块即便局部改进也难以在对称保真这一共同目标上形成合力。由此，三大问题构成“源头损耗—中游放大—全局固化”的传导闭环，单独改进任一模块都难以从根本上突破瓶颈，唯有引入一条贯穿全链路的统一主线方能系统性破解，这正是本研究以对称特征统摄四大环节的根本逻辑。




图 8 现有研究三大共性问题及其内在关联关系图

3.1.1 模态分解环节：对称约束缺失导致固有特征丢失

现有时序模态分解方法，无论是 EMD 类的递归筛分还是 VMD/MVMD 类的变分求解，在设计之初均以“信号平稳性最大化”或“模态复杂度最小化”为单一优化导向，将模态分解单纯视为信号去噪与降维的预处理手段^[9, 14, 15]。这一设计哲学的根本局限在于：负荷序列中蕴含的周期对称结构与频率互补对称结构，作为负荷演化的固有物理规律，并未被纳入分解的优化目标或约束条件。其直接后果是，原始负荷信号在分解阶段即发生对称特征的损耗与畸变——以周期中点为对称轴的镜像不变性被破坏，高低频分量的能量互补平衡被打乱，导致重构信号的对称保真度 SF 显著下降。

重要的是这种在信号处理最前端发生的对称特征丢失具有不可逆性：一旦分解结果丢失了对称信息，后续的特征关联分析与深度建模环节将无从恢复，只能在已经失真的分量上进行建模，从而形成对称特征在分解前端损耗、并在后续环节被固化难以恢复的传导链条。此外，国外研究普遍采用人工试凑法确定 MVMD 的模态数 K 与二次惩罚因子 α ^[15]，参数选取缺乏量化准则，分解质量高度依赖经验，进一步加剧了对称特征丢失的不确定性。这一问题的存在，使得后续无论采用多么精巧的深度模型，其建模对象本身已是失真表征，预测精度的提升因而存在结构性上限。

3.1.2 深度建模环节：对称感知缺位导致领域适配不足

C0252

事实核查：不实

判断来源：模型知识（未作联网查实）
置信度：86%
原文第 32 页

判断理由

EMD、VMD/MVMD 的目标分别涉及筛分经验准则或带宽约束变分建模，不能概括为所有方法均以单一平稳性或复杂度最小化、且仅作为去噪降维预处理。

C0253

事实核查：部分支持

判断来源：模型知识（未作联网查实）
置信度：90%
原文第 32 页

判断理由

经典 EMD/VMD 确实通常未显式加入本文定义的镜像或能量互补约束，但“所有现有方法”及这些结构是普适固有物理规律的说法过于绝对，无法据此全面确认。

C0255

事实核查：部分支持

判断来源：模型知识（未作联网查实）
置信度：87%
原文第 32 页

判断理由

分解表示丢失的信息可能难以恢复，但“不可逆”“无从恢复”是过强的普遍断言；后续模型可借助原始信号、冗余特征或联合训练部分补偿。

以 Transformer 及其变体为代表的深度时序预测模型，其核心架构聚焦于时序维度的长程依赖挖掘，即便是引入跨维度建模能力的 Crossformer，其两阶段注意力机制也仅从数据驱动的角度学习特征间的统计关联，缺乏面向电力负荷领域的对称先验归纳偏置^[28, 7]。如前一章所辨析，Autoformer 的自相关机制、FEDformer 的频域注意力虽具备一定的周期与频域建模能力，但其度量对象为关联强度与主导频率成分，并不显式约束镜像结构保持、能量配对均衡与方向对称^[25, 27]，因而不能等价替代对称感知。这一缺位带来三个层面的适配缺陷：其一，模型对气象、日期、负荷等多类特征之间的对称耦合关联建模能力薄弱，难以刻画影响因素与负荷之间稳定存在的双向信息传递对称关系，导致核心特征的协同效应未被充分利用；其二，标准模型的维度分段嵌入与位置编码未嵌入时序周期对称编码，无法主动适配电力负荷以日、周、年为周期的镜像对称规律，使得模型在周期转折点、对称时段的预测精度受限，领域泛化性能不足；其三，两阶段注意力等机制在结合多分量分解数据后存在显著的冗余计算，注意力矩阵规模随分量数与特征数增长而急剧膨胀，推理效率进一步下降，难以同时满足配电网调度对高精度与实时性的双重要求。归根结底，通用深度模型缺乏将对称先验作为显式归纳偏置注入模型结构的机制，导致其在电力负荷这一具有强对称规律的特定领域适配不足。

3.1.3 系统协同环节：优化目标割裂导致整体性能受限

现有混合预测框架虽然普遍采用“分解—优化—建模”的多模块串联结构，但各模块的优化目标彼此割裂、缺乏统一的设计主线，呈现出优化目标相互割裂的松耦合状态^[3, 59]。具体表现为：模态分解模块以包络熵、模态混叠系数等信号质量指标为优化目标，元启发式优化模块以单一预测精度指标为适应度函数，特征关联分析模块以静态全局关联系数为筛选准则，深度建模模块以均方误差为损失函数——四个模块各自追求局部最优，却没有一个贯穿始终的全局优化导向将其有机统一。这种松耦合结构带来三重弊端：一是对称约束未在模块间贯通，分解环节即便保留了部分对称特征，也无法通过统一的先验传递机制为下游建模所用；二是特征筛选采用静态离线策略，无法与深度模型的动态训练过程联动，难以捕捉极端工况下的短时强关联特征；三是各模块目标函数相互脱节，优化方向不一致甚至相互冲突，导致局部最优的简单叠加无法逼近全局最优，整体预测性能的提升遭遇瓶颈。由此可见，缺乏一条贯穿全流程的统一主线，是制约现有混合框架协同增效的深层原因。

3.2 论文研究领域的发展趋势

针对上述共性问题，结合人工智能与电力系统交叉领域的最新进展，可研判配电网短期负荷预测方法在未来一段时期内将呈现以下四个方面的发展趋势。

3.2.1 趋势一：从被动事后评价转向主动先验约束

传统研究将信号的物理特征（如对称性、周期性）视为分解完成后的评价指标，属于被动的事后评价范式。未来的发展趋势是将这些物理先验前置为分解与建模过程中的主动约束，即在优化目标函数中显式嵌入物理保真约束项，使算法在求解过程中主动保持信号的固有特征^[14, 49]。这一转变意味着“先验知识驱动”将与“数据驱动”深度融合，物理可解释性与数据拟合能力将不再是此消彼长的矛盾关系，而是协同增强的统一整体。就本课题而言，将对称保真由被动评价转化为主动约束，正是这一趋势在配电网负荷预测中的具体体现。

这一从被动评价转向主动约束的范式迁移，在多个相邻学科中已得到充分印证，构成本趋势研判的横向佐证。在信号处理领域，稀疏先验、低秩先验由早期单纯用于评价分解结果的“事后质量指标”，逐步演化为正则化项被直接写入优化目标，从而在求解过程中主动塑造解的结构特性；在机器学习领域，物理守恒律、对称等变性等先验亦由模型评估阶段的检验标准，前移为损失函数中的软约束或网络结构中的硬性归纳偏置，使模型在训练阶段即被引导满足领域规律^[82, 85]。这两条相互独立的演进轨迹共同指向同一规律：当某类先验知识被确认为问题的本质属性时，将其由被动评价前置为主动约束，往往能够同时改善求解质量与泛化能力。负荷对称性作为根植于人类用电节律的稳定统计规律，恰属于此类本质先验，因而将其由现有研究中的事后评价指标前置为分解与建模的主动约束，不仅符合本领域的内在需求，亦与上述跨学科范式迁移的总体方向高度一致，具备坚实的方法学合法性。

3.2.2 趋势二：从单一信号处理转向物理信息嵌入的智能建模

随着物理信息神经网络等范式的兴起^[82, 83]，将领域物理知识嵌入深度模型结构已成为提升模型领域适配性与泛化能力的重要方向。在负荷预测领域，这一趋势体现为将负荷的周期对称、频率互补对称等物理规律，通过专门设计的网络结构（如对称编码层、对称感知注意力偏置）注入模型，使深度模型不再是纯粹的黑箱拟合器，而是承载领域物理知识的灰箱模型^[84, 86]。物理信息的嵌入不仅能提升预测精度，更能增强

P085

AIGC / 改写倾向

分类分数 52.0%
置信度：低
原文第 34 页

判断依据

- 本段的统计贡献主要集中在“而言”、“这一”、“主动”、“增强”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 4 句，平均每句约 59 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“而言”、“这一”、“主动”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段包含 2 组数字、1 处引文，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

3.2 论文研究领域的发展趋势

针对上述共性问题，结合人工智能与电力系统交叉领域的最新进展，可研判配电网短期负荷预测方法在未来一段时期内将呈现以下四个方面的发展趋势。

3.2.1 趋势一：从被动事后评价转向主动先验约束

传统研究将信号的物理特征（如对称性、周期性）视为分解完成后的评价指标，属于被动的事后评价范式。未来的发展趋势是将这些物理先验前置为分解与建模过程中的主动约束，即在优化目标函数中显式嵌入物理保真约束项，使算法在求解过程中主动保持信号的固有特征^[14, 49]。这一转变意味着“先验知识驱动”将与“数据驱动”深度融合，物理可解释性与数据拟合能力将不再是此消彼长的矛盾关系，而是协同增强的统一整体。就本课题而言，将对称保真由被动评价转化为主动约束，正是这一趋势在配电网负荷预测中的具体体现。

这一从被动评价转向主动约束的范式迁移，在多个相邻学科中已得到充分印证，构成本趋势研判的横向佐证。在信号处理领域，稀疏先验、低秩先验由早期单纯用于评价分解结果的“事后质量指标”，逐步演化为正则化项被直接写入优化目标，从而在求解过程中主动塑造解的结构特性；在机器学习领域，物理守恒律、对称等变性等先验亦由模型评估阶段的检验标准，前移为损失函数中的软约束或网络结构中的硬性归纳偏置，使模型在训练阶段即被引导满足领域规律^[82, 85]。这两条相互独立的演进轨迹共同指向同一规律：当某类先验知识被确认为问题的本质属性时，将其由被动评价前置为主动约束，往往能够同时改善求解质量与泛化能力。负荷对称性作为根植于人类用电节律的稳定统计规律，恰属于此类本质先验，因而将其由现有研究中的事后评价指标前置为分解与建模的主动约束，不仅符合本领域的内在需求，亦与上述跨学科范式迁移的总体方向高度一致，具备坚实的方法学合法性。

3.2.2 趋势二：从单一信号处理转向物理信息嵌入的智能建模

随着物理信息神经网络等范式的兴起^[82, 83]，将领域物理知识嵌入深度模型结构已成为提升模型领域适配性与泛化能力的重要方向。在负荷预测领域，这一趋势体现为将负荷的周期对称、频率互补对称等物理规律，通过专门设计的网络结构（如对称编码层、对称感知注意力偏置）注入模型，使深度模型不再是纯粹的黑箱拟合器，而是承载领域物理知识的灰箱模型^[84, 86]。物理信息的嵌入不仅能提升预测精度，更能增强

P086

AIGC / 改写倾向

分类分数 54.0%
置信度：低
原文第 34 页

判断依据

- 本段的统计贡献主要集中在“领域”、“因而”、“主动”、“约束”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 5 句，平均每句约 79 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“领域”、“因而”、“主动”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“因而”、“同时”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 2 组数字、1 处引文，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

模型在小样本、极端工况下的鲁棒性与可解释性，这对于配电网这一安全攸关的应用场景尤为重要。

3.2.3 趋势三：从静态特征筛选转向动态自适应关联感知

传统特征关联分析以全量数据的静态全局关联系数为筛选依据，忽视了负荷与影响因子关联强度的时变特性。未来的发展趋势是构建动态自适应的关联感知机制，能够实时识别极端气象、临时节假日等场景下出现的短时强关联特征，并将动态关联信息及时传递至预测模型^[36, 38]。同时，关联分析将从单纯的强度度量拓展至关联结构的对称性、方向性刻画，为对称感知建模提供更丰富、更精准的特征先验。这种从静态到动态、从单向到双向的演进，将显著提升特征工程对负荷演化不确定性的适应能力。

3.2.4 趋势四：从模块松耦合转向全链路统一目标的紧耦合

现有混合框架的松耦合结构是制约性能突破的深层瓶颈，未来的发展趋势是以某一统一主线（如本课题的对称特征）为内核，将寻优、分解、关联、建模四大环节的优化目标在同一框架下协同设计，构建全链路紧耦合的一体化预测体系^[48]。在这一体系中，各模块不再独立优化，而是围绕统一的全局目标（如对称保真度最大化）形成正向反馈闭环：优化模块为分解提供参数，分解为建模输出保真分量，关联分析为建模提供对称先验，建模反向牵引前序环节的目标设计。这种紧耦合的协同范式，是突破局部最优简单叠加困境、实现整体性能跃升的必由之路。

3.3 研究现状分析结论

综合上述对国内外研究现状的系统梳理、共性问题的凝练与发展趋势的研判，可以得出如下研究现状分析结论：现有配电网短期负荷预测研究虽已形成“信号分解 + 深度学习 + 智能优化”的成熟混合框架，但普遍缺失一条贯穿全流程的统一主线，致使负荷固有的对称物理规律在分解、寻优、关联、建模各环节被反复损耗，成为制约预测性能进一步突破的根本瓶颈。

值得客观说明的是，本课题组围绕对称感知负荷预测这一方向已开展前期探索，相关阶段性成果以协同增强的 KMA-MVMD-Crossformer 框架为题发表于对称科学领域国际期刊 Symmetry^[48]，初步验证了以对称先验贯通寻优—分解—预测全链路的科

P091

AIGC / 改写倾向

分类分数 56.0%

置信度：低

原文第 35-36 页（跨页）

判断依据

1. 本段的统计贡献主要集中在“因此”、“仍存在”、“现实”、“围绕”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
2. 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
3. 本段可切分为 5 句，平均每句约 85 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

1. 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
2. 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
3. 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

1. 回看“因此”、“仍存在”、“现实”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
2. 核对“因此”、“进一步”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
3. 本段包含 1 组数字、1 处引文、2 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
4. 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

学可行性。客观评述该前期成果：其贡献在于首次将对称先验作为统一线索引入混合预测框架并在公开数据集上验证了有效性，从而为本研究的系统化展开提供了可行性依据；其局限亦较为明确。一是对称保真约束的形式化定义与三类对称指标的判据体系仍有待进一步严格化与统一，二是对称约束分解、双向关联对称度筛选与对称感知建模之间的紧耦合机理尚未充分打通，三是在更大规模、更多类型台区数据以及极端工况下的鲁棒性与泛化性仍需系统检验。因此，该前期工作表明对称感知方向具有现实可行性而非“完全空白”，但其方法体系的完备性、机理的严谨性与适用范围的广度仍存在明显提升空间，这恰为本研究在更系统、更严格层面深化对称感知预测框架提供了直接出发点。

基于上述判断，本研究确立以“对称性先验”为统一主线，构建贯穿“智能优化—模态分解—特征关联—深度建模”四大环节的一体化对称感知预测框架，其总体技术路线如图 8 所示。该框架以对称特征贯穿全流程为核心理念，自底向上分为数据层、优化与分解层、预测建模层、框架集成与验证层，四层之间通过对称先验逐层传递、紧密耦合，从根本上扭转现有研究对称特征缺失的被动局面。需要说明的是，本综述作为文献综述，仅在此明确研究切入点与四个研究方向的总体设想，其具体的数学推导、算法流程、模型结构设计与实验验证将在后续学位论文正文中系统展开，本章不予赘述。

P091

AIGC / 改写倾向

分类分数 56.0%

置信度：低

原文第 35-36 页（跨页）

判断依据

- 本段的统计贡献主要集中在“因此”，“仍存在”、“现实”、“围绕”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 5 句，平均每句约 85 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“因此”，“仍存在”、“现实”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 核对“因此”、“进一步”等衔接词是否来自原稿，还是在后期润色中被集中补入，并检查删去后论述关系是否仍然成立。
- 本段包含 1 组数字、1 处引文、2 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段长短句差异较明显，人工复核时不要只看语言是否流畅，应重点比较命题顺序和限定条件是否被重新组织。

■ 红色：AIGC / 改写倾向

■ 橙色：AI 润色倾向

蓝线：事实问题

紫线：引用问题

完整依据见页边批注及批注续页



图 9 EnKMA-MVMD-Crossformer 一体化对称感知预测技术路线图

围绕这一总体框架，本研究在方法层面凝练出四个相互支撑、有机融合的研究方向，分别对应缓解前述三大共性问题，作为本综述确立的后续研究切入点简述如下，不展开具体方法推导。

为更直观地梳理本综述四个研究方向与现有研究现状之间的对应关系，现将研究方向、对应研究现状、主要不足及本综述切入点整体归纳如表所示。

研究方向	对应研究现状	主要不足/空白	本综述拟解决的切入点
对称约束型模态分解与对称保真表征	现有 EMD、VMD、MVMD 等方法已形成较成熟的分解体系，并在负荷预测中广泛应用。	主流方法多以平稳性、复杂度最小化或重构误差为单一目标，缺少对周期对称与频率互补对称的显式约束。	在 MVMD 变分目标函数中嵌入对称保真约束项，使分解过程在追求模态正交性与重构精度的同时主动保持负荷固有对称结构。
混沌增强元启发式优化与参数自适应寻优	GA、PSO、SSA、GWO、KMA 等算法已广泛用于分解参数与模型超参数优化。	现有算法在高维、强噪声场景下仍易陷局部最优、后期收敛慢，且适应度函数较少纳入对称保真目标。	以 KMA 为基础融合 Logistic 混沌初始化、非线性时变惯性权重与 Tent 混沌扰动构建 EnKMA，并设计兼顾分解精度、模态正交性与对称保真度的多目标适应度函数。
双向关联对称度分析与动态特征筛选	皮尔逊相关、互信息、MIC、RapidMIC 等方法已用于负荷影响因子分析与特征筛选。	现有研究多采用静态离线筛选，缺少对时变关联与双向信息传递均衡性的刻画。	基于 MVRapidMIC 构造因子→负荷与负荷→因子的双向关联对称度，实现动态筛选与对称先验传递。
对称感知深度时序建模	Transformer、Informer、Autoformer、FEDformer、Crossformer 等模型显著提升了长时序预测能力。	通用模型对电力负荷周期对称、频率互补对称及特征关联对称的显式建模不足，领域适配性受限。	以 Crossformer 为基座，在维度分段嵌入中引入时序周期对称编码、在两阶段注意力中构造对称感知偏置，建立分分量预测与全局重构框架。

表 1 研究方向与研究现状对应关系总览

3.3.1 研究方向一：对称约束型模态分解与对称保真表征

针对模态分解环节对称约束缺失的问题，本研究拟提出对称约束型多元变分模态分解，在传统变分目标函数中显式嵌入周期对称与频率互补对称的保真约束项，使分解过程在追求模态正交性与重构精度的同时，主动保持负荷固有的对称特征。该方向

P093

AIGC / 改写倾向

分类分数 67.0%
置信度：低
原文第 38 页

判断依据

- 本段的统计贡献主要集中在“问题”、“围绕”、“支撑”、“后续”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 1 句，平均每句约 81 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 本段只有约 82 个有效字符，可观察到的局部模式较少，分类稳定性有限。

复核建议

- 回看“问题”、“围绕”、“支撑”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

图 9 EnKMA-MVMD-Crossformer 一体化对称感知预测技术路线图

围绕这一总体框架，本研究在方法层面凝练出四个相互支撑、有机融合的研究方向，分别对应缓解前述三大共性问题，作为本综述确立的后续研究切入点简述如下，不展开具体方法推导。

为更直观地梳理本综述四个研究方向与现有研究现状之间的对应关系，现将研究方向、对应研究现状、主要不足及本综述切入点整体归纳如表所示。

研究方向	对应研究现状	主要不足/空白	本综述拟解决的切入点
对称约束型模态分解与对称保真表征	现有 EMD、VMD、MVMD 等方法已形成较成熟的分解体系，并在负荷预测中广泛应用。	主流方法多以平稳性、复杂度最小化或重构误差为单一目标，缺少对周期对称与频率互补对称的显式约束。	在 MVMD 变分目标函数中嵌入对称保真约束项，使分解过程在追求模态正交性与重构精度的同时主动保持负荷固有对称结构。
混沌增强元启发式优化与参数自适应寻优	GA、PSO、SSA、GWO、KMA 等算法已广泛用于分解参数与模型超参数优化。	现有算法在高维、强噪声场景下仍易陷局部最优、后期收敛慢，且适应度函数较少纳入对称保真目标。	以 KMA 为基础融合 Logistic 混沌初始化、非线性时变惯性权重与 Tent 混沌扰动构建 EnKMA，并设计兼顾分解精度、模态正交性与对称保真度的多目标适应度函数。
双向关联对称度分析与动态特征筛选	皮尔逊相关、互信息、MIC、RapidMIC 等方法已用于负荷影响因子分析与特征筛选。	现有研究多采用静态离线筛选，缺少对时变关联与双向信息传递均衡性的刻画。	基于 MVRapidMIC 构造因子→负荷与负荷→因子的双向关联对称度，实现动态筛选与对称先验传递。
对称感知深度时序建模	Transformer、Informer、Autoformer、FEDformer、Crossformer 等模型显著提升了长时序预测能力。	通用模型对电力负荷周期对称、频率互补对称及特征关联对称的显式建模不足，领域适配性受限。	以 Crossformer 为基座，在维度分段嵌入中引入时序周期对称编码、在两阶段注意力中构造对称感知偏置，建立分分量预测与全局重构框架。

表 1 研究方向与研究现状对应关系总览

3.3.1 研究方向一：对称约束型模态分解与对称保真表征

针对模态分解环节对称约束缺失的问题，本研究拟提出对称约束型多元变分模态分解，在传统变分目标函数中显式嵌入周期对称与频率互补对称的保真约束项，使分解过程在追求模态正交性与重构精度的同时，主动保持负荷固有的对称特征。该方向

P095

AIGC / 改写倾向

分类分数 53.0%
置信度：低
原文第 38 页

判断依据

- 本段的统计贡献主要集中在“中广泛应用”、“解体系，并在”、“形成”、“不足”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 1 句，平均每句约 83 字；低权重辅助统计分别略偏向自然差异和整体重写，与最终标签并不完全一致，说明本段同时存在反向信号，最终结果主要由局部组合决定。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 本段只有约 84 个有效字符，可观察到的局部模式较少，分类稳定性有限。

复核建议

- 回看“中广泛应用”、“解体系，并在”、“形成”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段包含 3 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

图 9 EnKMA-MVMD-Crossformer 一体化对称感知预测技术路线图

围绕这一总体框架，本研究在方法层面凝练出四个相互支撑、有机融合的研究方向，分别对应缓解前述三大共性问题，作为本综述确立的后续研究切入点简述如下，不展开具体方法推导。

为更直观地梳理本综述四个研究方向与现有研究现状之间的对应关系，现将研究方向、对应研究现状、主要不足及本综述切入点整体归纳如表所示。

研究方向	对应研究现状	主要不足/空白	本综述拟解决的切入点
对称约束型模态分解与对称保真表征	现有 EMD、VMD、MVMD 等方法已形成较成熟的分解体系，并在负荷预测中广泛应用。	主流方法多以平稳性、复杂度最小化或重构误差为单一目标，缺少对周期对称与频率互补对称的显式约束。	在 MVMD 变分目标函数中嵌入对称保真约束项，使分解过程在追求模态正交性与重构精度的同时主动保持负荷固有对称结构。
混沌增强元启发式优化与参数自适应寻优	GA、PSO、SSA、GWO、KMA 等算法已广泛用于分解参数与模型超参数优化。	现有算法在高维、强噪声场景下仍易陷局部最优、后期收敛慢，且适应度函数较少纳入对称保真目标。	以 KMA 为基础融合 Logistic 混沌初始化、非线性时变惯性权重与 Tent 混沌扰动构建 EnKMA，并设计兼顾分解精度、模态正交性与对称保真度的多目标适应度函数。
双向关联对称度分析与动态特征筛选	皮尔逊相关、互信息、MIC、RapidMIC 等方法已用于负荷影响因子分析与特征筛选。	现有研究多采用静态离线筛选，缺少对时变关联与双向信息传递均衡性的刻画。	基于 MVRapidMIC 构造因子→负荷与负荷→因子的双向关联对称度，实现动态筛选与对称先验传递。
对称感知深度时序建模	Transformer、Informer、Autoformer、FEDformer、Crossformer 等模型显著提升了长时序预测能力。	通用模型对电力负荷周期对称、频率互补对称及特征关联对称的显式建模不足，领域适配性受限。	以 Crossformer 为基座，在维度分段嵌入中引入时序周期对称编码、在两阶段注意力中构造对称感知偏置，建立分分量预测与全局重构框架。

表 1 研究方向与研究现状对应关系总览

3.3.1 研究方向一：对称约束型模态分解与对称保真表征

针对模态分解环节对称约束缺失的问题，本研究拟提出对称约束型多元变分模态分解，在传统变分目标函数中显式嵌入周期对称与频率互补对称的保真约束项，使分解过程在追求模态正交性与重构精度的同时，主动保持负荷固有的对称特征。该方向

P099

AIGC / 改写倾向

分类分数 60.0%
置信度：低
原文第 38 页

判断依据

- 本段的统计贡献主要集中在“性与”、“目标”、“适应”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 1 句，平均每句约 79 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 本段只有约 80 个有效字符，可观察到的局部模式较少，分类稳定性有限。

复核建议

- 回看“性与”、“目标”、“适应”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段包含 4 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

图 9 EnKMA-MVMD-Crossformer 一体化对称感知预测技术路线图

围绕这一总体框架，本研究在方法层面凝练出四个相互支撑、有机融合的研究方向，分别对应缓解前述三大共性问题，作为本综述确立的后续研究切入点简述如下，不展开具体方法推导。

为更直观地梳理本综述四个研究方向与现有研究现状之间的对应关系，现将研究方向、对应研究现状、主要不足及本综述切入点整体归纳如表所示。

研究方向	对应研究现状	主要不足/空白	本综述拟解决的切入点
对称约束型模态分解与对称保真表征	现有 EMD、VMD、MVMD 等方法已形成较成熟的分解体系，并在负荷预测中广泛应用。	主流方法多以平稳性、复杂度最小化或重构误差为单一目标，缺少对周期对称与频率互补对称的显式约束。	在 MVMD 变分目标函数中嵌入对称保真约束项，使分解过程在追求模态正交性与重构精度的同时主动保持负荷固有对称结构。
混沌增强元启发式优化与参数自适应寻优	GA、PSO、SSA、GWO、KMA 等算法已广泛用于分解参数与模型超参数优化。	现有算法在高维、强噪声场景下仍易陷局部最优、后期收敛慢，且适应度函数较少纳入对称保真目标。	以 KMA 为基础融合 Logistic 混沌初始化、非线性时变惯性权重与 Tent 混沌扰动构建 EnKMA，并设计兼顾分解精度、模态正交性与对称保真度的多目标适应度函数。
双向关联对称度分析与动态特征筛选	皮尔逊相关、互信息、MIC、RapidMIC 等方法已用于负荷影响因子分析与特征筛选。	现有研究多采用静态离线筛选，缺少对时变关联与双向信息传递均衡性的刻画。	基于 MVRapidMIC 构造因子→负荷与负荷→因子的双向关联对称度，实现动态筛选与对称先验传递。
对称感知深度时序建模	Transformer、Informer、Autoformer、FEDformer、Crossformer 等模型显著提升了长时序预测能力。	通用模型对电力负荷周期对称、频率互补对称及特征关联对称的显式建模不足，领域适配性受限。	以 Crossformer 为基座，在维度分段嵌入中引入时序周期对称编码、在两阶段注意力中构造对称感知偏置，建立分分量预测与全局重构框架。

表 1 研究方向与研究现状对应关系总览

3.3.1 研究方向一：对称约束型模态分解与对称保真表征

针对模态分解环节对称约束缺失的问题，本研究拟提出对称约束型多元变分模态分解，在传统变分目标函数中显式嵌入周期对称与频率互补对称的保真约束项，使分解过程在追求模态正交性与重构精度的同时，主动保持负荷固有的对称特征。该方向

P101

AIGC / 改写倾向

分类分数 87.0%

置信度：低

原文第 38 页

- 判断依据
1. 本段的统计贡献主要集中在“纳入”、“较少”、“目标”、“现有”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。

2. 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。

3. 本段可切分为 1 句，平均每句约 44 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

- 反向证据
1. 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。

2. 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。

3. 本段只有约 45 个有效字符，可观察到的局部模式较少，分类稳定性有限。

- 复核建议
1. 回看“纳入”、“较少”、“目标”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。

2. 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

图 9 EnKMA-MVMD-Crossformer 一体化对称感知预测技术路线图

围绕这一总体框架，本研究在方法层面凝练出四个相互支撑、有机融合的研究方向，分别对应缓解前述三大共性问题，作为本综述确立的后续研究切入点简述如下，不展开具体方法推导。

为更直观地梳理本综述四个研究方向与现有研究现状之间的对应关系，现将研究方向、对应研究现状、主要不足及本综述切入点整体归纳如表所示。

研究方向	对应研究现状	主要不足/空白	本综述拟解决的切入点
对称约束型模态分解与对称保真表征	现有 EMD、VMD、MVMD 等方法已形成较成熟的分解体系，并在负荷预测中广泛应用。	主流方法多以平稳性、复杂度最小化或重构误差为单一目标，缺少对周期对称与频率互补对称的显式约束。	在 MVMD 变分目标函数中嵌入对称保真约束项，使分解过程在追求模态正交性与重构精度的同时主动保持负荷固有对称结构。
混沌增强元启发式优化与参数自适应寻优	GA、PSO、SSA、GWO、KMA 等算法已广泛用于分解参数与模型超参数优化。	现有算法在高维、强噪声场景下仍易陷局部最优、后期收敛慢，且适应度函数较少纳入对称保真目标。	以 KMA 为基础融合 Logistic 混沌初始化、非线性时变惯性权重与 Tent 混沌扰动构建 EnKMA，并设计兼顾分解精度、模态正交性与对称保真度的多目标适应度函数。
双向关联对称度分析与动态特征筛选	皮尔逊相关、互信息、MIC、RapidMIC 等方法已用于负荷影响因子分析与特征筛选。	现有研究多采用静态离线筛选，缺少对时变关联与双向信息传递均衡性的刻画。	基于 MVRapidMIC 构造因子→负荷与负荷→因子的双向关联对称度，实现动态筛选与对称先验传递。
对称感知深度时序建模	Transformer、Informer、Autoformer、FEDformer、Crossformer 等模型显著提升了长时序预测能力。	通用模型对电力负荷周期对称、频率互补对称及特征关联对称的显式建模不足，领域适配性受限。	以 Crossformer 为基座，在维度分段嵌入中引入时序周期对称编码、在两阶段注意力中构造对称感知偏置，建立分分量预测与全局重构框架。

表 1 研究方向与研究现状对应关系总览

3.3.1 研究方向一：对称约束型模态分解与对称保真表征

针对模态分解环节对称约束缺失的问题，本研究拟提出对称约束型多元变分模态分解，在传统变分目标函数中显式嵌入周期对称与频率互补对称的保真约束项，使分解过程在追求模态正交性与重构精度的同时，主动保持负荷固有的对称特征。该方向

P096

AIGC / 改写倾向

分类分数 83.0%
置信度：低
原文第 38 页

判断依据

- 本段的统计贡献主要集中在“用于”、“增强”、“优化”、“适应”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 1 句，平均每句约 45 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 本段只有约 46 个有效字符，可观察到的局部模式较少，分类稳定性有限。

复核建议

- 回看“用于”、“增强”、“优化”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段包含 2 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

图 9 EnKMA-MVMD-Crossformer 一体化对称感知预测技术路线图

围绕这一总体框架，本研究在方法层面凝练出四个相互支撑、有机融合的研究方向，分别对应缓解前述三大共性问题，作为本综述确立的后续研究切入点简述如下，不展开具体方法推导。

为更直观地梳理本综述四个研究方向与现有研究现状之间的对应关系，现将研究方向、对应研究现状、主要不足及本综述切入点整体归纳如表所示。

研究方向	对应研究现状	主要不足/空白	本综述拟解决的切入点
对称约束型模态分解与对称保真表征	现有 EMD、VMD、MVMD 等方法已形成较成熟的分解体系，并在负荷预测中广泛应用。	主流方法多以平稳性、复杂度最小化或重构误差为单一目标，缺少对周期对称与频率互补对称的显式约束。	在 MVMD 变分目标函数中嵌入对称保真约束项，使分解过程在追求模态正交性与重构精度的同时主动保持负荷固有对称结构。
混沌增强元启发式优化与参数自适应寻优	GA、PSO、SSA、GWO、KMA 等算法已广泛用于分解参数与模型超参数优化。	现有算法在高维、强噪声场景下仍易陷局部最优、后期收敛慢，且适应度函数较少纳入对称保真目标。	以 KMA 为基础融合 Logistic 混沌初始化、非线性时变惯性权重与 Tent 混沌扰动构建 EnKMA，并设计兼顾分解精度、模态正交性与对称保真度的多目标适应度函数。
双向关联对称度分析与动态特征筛选	皮尔逊相关、互信息、MIC、RapidMIC 等方法已用于负荷影响因子分析与特征筛选。	现有研究多采用静态离线筛选，缺少对时变关联与双向信息传递均衡性的刻画。	基于 MVRapidMIC 构造因子→负荷与负荷→因子的双向关联对称度，实现动态筛选与对称先验传递。
对称感知深度时序建模	Transformer、Informer、Autoformer、FEDformer、Crossformer 等模型显著提升了长时序预测能力。	通用模型对电力负荷周期对称、频率互补对称及特征关联对称的显式建模不足，领域适配性受限。	以 Crossformer 为基座，在维度分段嵌入中引入时序周期对称编码、在两阶段注意力中构造对称感知偏置，建立分分量预测与全局重构框架。

表 1 研究方向与研究现状对应关系总览

3.3.1 研究方向一：对称约束型模态分解与对称保真表征

针对模态分解环节对称约束缺失的问题，本研究拟提出对称约束型多元变分模态分解，在传统变分目标函数中显式嵌入周期对称与频率互补对称的保真约束项，使分解过程在追求模态正交性与重构精度的同时，主动保持负荷固有的对称特征。该方向

P097

AIGC / 改写倾向

分类分数 59.0%
置信度：低
原文第 38 页

判断依据

- 本段的统计贡献主要集中在“型显著提升了”、“分析与”、“能力。”、“特征”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 2 句，平均每句约 62 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 数字、引文和英文技术标识可能由研究对象本身决定，不能因为它们排列规整就推断为 AI 写作。

复核建议

- 回看“型显著提升了”、“分析与”、“能力。”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段包含 6 个英文技术标识，建议与原稿或参考文献逐项核对，确认改写没有改变数值、对象及限定条件。

图 9 EnKMA-MVMD-Crossformer 一体化对称感知预测技术路线图

围绕这一总体框架，本研究在方法层面凝练出四个相互支撑、有机融合的研究方向，分别对应缓解前述三大共性问题，作为本综述确立的后续研究切入点简述如下，不展开具体方法推导。

为更直观地梳理本综述四个研究方向与现有研究现状之间的对应关系，现将研究方向、对应研究现状、主要不足及本综述切入点整体归纳如表所示。

研究方向	对应研究现状	主要不足/空白	本综述拟解决的切入点
对称约束型模态分解与对称保真表征	现有 EMD、VMD、MVMD 等方法已形成较成熟的分解体系，并在负荷预测中广泛应用。	主流方法多以平稳性、复杂度最小化或重构误差为单一目标，缺少对周期对称与频率互补对称的显式约束。	在 MVMD 变分目标函数中嵌入对称保真约束项，使分解过程在追求模态正交性与重构精度的同时主动保持负荷固有对称结构。
混沌增强元启发式优化与参数自适应寻优	GA、PSO、SSA、GWO、KMA 等算法已广泛用于分解参数与模型超参数优化。	现有算法在高维、强噪声场景下仍易陷局部最优、后期收敛慢，且适应度函数较少纳入对称保真目标。	以 KMA 为基础融合 Logistic 混沌初始化、非线性时变惯性权重与 Tent 混沌扰动构建 EnKMA，并设计兼顾分解精度、模态正交性与对称保真度的多目标适应度函数。
双向关联对称度分析与动态特征筛选	皮尔逊相关、互信息、MIC、RapidMIC 等方法已用于负荷影响因子分析与特征筛选。	现有研究多采用静态离线筛选，缺少对时变关联与双向信息传递均衡性的刻画。	基于 MVRapidMIC 构造因子→负荷与负荷→因子的双向关联对称度，实现动态筛选与对称先验传递。
对称感知深度时序建模	Transformer、Informer、Autoformer、FEDformer、Crossformer 等模型显著提升了长时序预测能力。	通用模型对电力负荷周期对称、频率互补对称及特征关联对称的显式建模不足，领域适配性受限。	以 Crossformer 为基座，在维度分段嵌入中引入时序周期对称编码、在两阶段注意力中构造对称感知偏置，建立分分量预测与全局重构框架。

表 1 研究方向与研究现状对应关系总览

3.3.1 研究方向一：对称约束型模态分解与对称保真表征

针对模态分解环节对称约束缺失的问题，本研究拟提出对称约束型多元变分模态分解，在传统变分目标函数中显式嵌入周期对称与频率互补对称的保真约束项，使分解过程在追求模态正交性与重构精度的同时，主动保持负荷固有的对称特征。该方向

P103

AIGC / 改写倾向

分类分数 69.0%
置信度：低
原文第 38 页

判断依据

- 本段的统计贡献主要集中在“不足”、“特征”、“适配”等位置，在两个统计步骤上共同呈现更接近整体改写的相关分布；单个词组本身不是 AIGC 证据。
- 两步统计在当前段落上均指向较强的表达重组，因此不是由单一连接词、术语或排版形式触发的结论。
- 本段可切分为 1 句，平均每句约 40 字；句长、用字丰富度、重复度与压缩特征组成的低权重辅助统计，在本段分别略偏向经过变换和整体重写，与局部组合的总体方向一致。

反向证据

- 正式、流畅、结构完整或术语密集也可能来自正常学术写作，本次没有把这些表面特征单独作为 AIGC 依据。
- 当前未使用已知学科的专门校准，跨学科写作习惯可能影响结果。
- 本段只有约 40 个有效字符，可观察到的局部模式较少，分类稳定性有限。

复核建议

- 回看“不足”、“特征”、“适配”附近的表达及其在相邻段落中的使用：若多段反复以相同组合组织观点，应检查是否经过批量改写；若属于学科固定搭配，则应降低其解释权重。
- 本段句子数量过少，建议合并阅读前后段落后再判断，不要仅凭这一段作出处置。

的核心是将“对称保真”由被动的事后评价转化为主动的分解约束，从信号处理最前端缓解对称特征丢失的共性难题，为下游各环节提供高质量、保对称的输入表征^[14, 15]。

3.3.2 研究方向二：混沌增强元启发式优化与参数自适应寻优

针对分解参数依赖人工试凑、传统群智能算法易陷局部最优的问题，本研究拟以新型科莫多龙优化算法为基础，融合 Logistic 混沌映射初始化、非线性时变惯性权重与 Tent 混沌扰动等多重策略，构建混沌增强 KMA，并设计兼顾分解精度、模态正交性与对称保真度的多目标适应度函数，为模态数 K 与惩罚因子 α 的自适应联合寻优提供高性能、高鲁棒性的优化引擎^[44, 46, 47]。

3.3.3 研究方向三：双向关联对称度分析与动态特征筛选

针对静态特征筛选难以捕捉时变关联、未结合对称映射规律的问题，本研究拟提出基于多元快速最大信息系数的双向关联对称度分析方法，构造因子 $\rightarrow$ 负荷与负荷 $\rightarrow$ 因子的双向最大信息系数，定义关联对称度 SP_corr ，定向筛选既强关联又信息传递均衡的核心特征，并将所得对称关联矩阵作为对称感知注意力偏置的先验输入，实现特征关联分析与深度建模的有机贯通^[36, 38]。

3.3.4 研究方向四：对称感知深度时序建模

针对通用深度模型对称感知缺位、领域适配不足的问题，本研究拟以 Crossformer 为基座，在维度分段嵌入中引入时序周期对称编码，在两阶段注意力中构造对称关联感知偏置，并针对不同对称特性的 IMF 分量设计差异化建模策略，建立“分分量预测、全局重构”的预测范式，从模型结构层面实现对负荷对称规律的主动适配^[28, 7]。

上述四个研究方向以对称特征为统一主线层层递进、紧密耦合，共同构成“寻优—分解—关联—预测”的紧耦合闭环，是对现有研究共性瓶颈的系统性回应，也是本课题创新性与研究价值的集中体现。综上所述，本综述通过对国内外研究现状的系统评述，明确了配电网短期负荷预测在对称特征感知、约束与利用方面的共性缺口，研判了从被动评价到主动约束、从单一信号处理到物理信息嵌入、从静态筛选到动态感知、从模块松耦合到全链路紧耦合的发展趋势，并据此确立了以对称性先验为统一主线的研究切入点与四个研究方向，为后续学位论文正文的方法构建与实验验证奠定了文献基础与理论坐标。

参考文献

[1] 康重庆, 夏清, 刘梅. 电力系统负荷预测[M]. 北京: 中国电力出版社, 2017.

[2] 赵登福, 周琳, 王锡凡. 短期电力负荷预测方法综述与展望[J]. 中国电机工程学报, 2022, 42(22): 1-12.

[3] 刘开铭, 王艳, 尹成群. 基于变分模态分解与深度学习的配电网短期负荷预测[J]. 电工技术学报, 2021, 36(18): 3895-3906.

[4] HONG T, FAN S. Probabilistic electric load forecasting: A tutorial review[J]. International Journal of Forecasting, 2016, 32(3): 914-938.

[5] LIM B, ZOHREN S. Time-series forecasting with deep learning: A survey[J]. Philosophical Transactions of the Royal Society A, 2021, 379(2194): 20200209.

[6] 林立, 刘永前, 阎洁, 等. 基于深度学习的短期电力负荷预测综述[J]. 电力系统自动化, 2023, 47(4): 1-15.

[7] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017: 5998-6008.

[8] WEN Q, ZHOU T, ZHANG C, et al. Transformers in time series: A survey[C]//Proceedings of the 32nd International Joint Conference on Artificial Intelligence. 2023: 6778-6786.

[9] HUANG N E, SHEN Z, LONG S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings of the Royal Society of London A, 1998, 454(1971): 903-995.

[10] WU Z, HUANG N E. Ensemble empirical mode decomposition: A noise-assisted data analysis method[J]. Advances in Adaptive Data Analysis, 2009, 1(1): 1-41.

[11] LEI Y, LIN J, HE Z, et al. A review on empirical mode decomposition in fault diagnosis of rotating machinery[J]. Mechanical Systems and Signal Processing, 2013, 35(1-2): 108-126.

[12] TORRES M E, COLOMINAS M A, SCHLOTTHAUER G, et al. A complete ensemble empirical mode decomposition with adaptive noise[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. 2011: 4144-4147.

[13] COLOMINAS M A, SCHLOTTHAUER G, TORRES M E. Improved complete ensemble EMD: A suitable tool for biomedical signal processing[J]. Biomedical Signal Processing and Control, 2014, 14: 19-29.

[14] DRAGOMIRETSKIY K, ZOSSO D. Variational mode decomposition[J]. IEEE Transactions on Signal Processing, 2014, 62(3): 531-544.

[15] REHMAN N U, AFTAB H. Multivariate variational mode decomposition[J]. IEEE Transactions on Signal Processing, 2019, 67(23): 6039-6052.

[16] 孙波, 李庚银, 周明. 基于改进 VMD 与混合神经网络的短期负荷预测[J]. 电网技术, 2022, 46(5): 1923-1931.

[17] 马辉, 刘沛津, 谷立臣. 多元变分模态分解算法及其在故障诊断中的应用[J]. 仪器仪表学报, 2020, 41(7): 178-186.

[18] ZHANG G, WEI C, JING C, et al. Short-term electrical load forecasting based on VMD and GRU-Attention[J]. Energies, 2022, 15(3): 1219.

[19] RICHMAN J S, MOORMAN J R. Physiological time-series analysis using approximate entropy and sample entropy[J]. American Journal of Physiology-Heart and Circulatory Physiology, 2000, 278(6): H2039-H2049.

[20] BANDT C, POMPE B. Permutation entropy: A natural complexity measure for time series[J]. Physical Review Letters, 2002, 88(17): 174102.

[21] 郑近德, 程军圣, 杨宇. 复合多尺度模糊熵及其在滚动轴承故障诊断中的应用[J]. 振动与冲击, 2015, 34(9): 100-104.

[22] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[23] CHO K, VAN MERRIENBOER B, GULCEHRE C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. 2014: 1724-1734.

[24] ZHOU H, ZHANG S, PENG J, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021, 35(12): 11106-11115.

[25] WU H, XU J, WANG J, et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting[C]//Advances in Neural Information Processing Systems. 2021: 22419-22430.

[26] KITAEV N, KAISER L, LEVSKAYA A. Reformer: The efficient transformer[C]//International Conference on Learning Representations. 2020.

[27] ZHOU T, MA Z, WEN Q, et al. FEDformer: Frequency enhanced decomposed transformer for long-term series forecasting[C]//Proceedings of the 39th International Conference on Machine Learning. 2022: 27268-27286.

[28] ZHANG Y, YAN J. Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting[C]//International Conference on Learning Representations. 2023.

[29] LAI G, CHANG W C, YANG Y, et al. Modeling long- and short-term temporal patterns with deep neural networks[C]//Proceedings of the 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. 2018: 95-104.

[30] BAI S, KOLTER J Z, KOLTUN V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J]. arXiv preprint arXiv:1803.01271, 2018.

[31] WU Z, PAN S, LONG G, et al. Graph WaveNet for deep spatial-temporal graph modeling[C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence. 2019: 1907-1913.

[32] 王健. 基于 Transformer 及其变体的电力时序预测方法研究[D]. 北京: 华北电力大学, 2023.

[33] HAN K, WANG Y, CHEN H, et al. A survey on vision transformer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(1): 87-110.

[34] LIANG T, GLOSSNER J, WANG L, et al. Pruning and quantization for deep neural network acceleration: A survey[J]. Neurocomputing, 2021, 461: 370-403.

[35] PEARSON K. Notes on regression and inheritance in the case of two parents[J]. Proceedings of the Royal Society of London, 1895, 58: 240-242.

[36] RESHEF D N, RESHEF Y A, FINUCANE H K, et al. Detecting novel associations in large data sets[J]. Science, 2011, 334(6062): 1518-1524.

[37] KRASKOV A, STOGBAUER H, GRASSBERGER P. Estimating mutual information[J]. Physical Review E, 2004, 69(6): 066138.

[38] TANG D, WANG J, YANG J, et al. RapidMic: Rapid computation of the maximal information coefficient[J]. Evolutionary Bioinformatics, 2014, 10: 11-16.

[39] HOLLAND J H. Adaptation in natural and artificial systems[M]. Ann Arbor: University of Michigan Press, 1975.

[40] KENNEDY J, EBERHART R. Particle swarm optimization[C]//Proceedings of the IEEE International Conference on Neural Networks. 1995: 1942-1948.

[41] XUE J, SHEN B. A novel swarm intelligence optimization approach: Sparrow search algorithm[J]. Systems Science & Control Engineering, 2020, 8(1): 22-34.

[42] MIRJALILI S, MIRJALILI S M, LEWIS A. Grey wolf optimizer[J]. Advances in Engineering Software, 2014, 69: 46-61.

[43] MIRJALILI S, LEWIS A. The whale optimization algorithm[J]. Advances in Engineering Software, 2016, 95: 51-67.

[44] SUYANTO S, ARIYANTO A A, ARIYANTO A F. Komodo Mlipir Algorithm[J]. Applied Soft Computing, 2022, 114: 108043.

[45] 陈哲. 基于群智能优化算法的模式分解参数优化及负荷预测研究[D]. 重庆: 重庆大学, 2022.

[46] 黄传金, 杜文霞, 曲良东. 混沌映射改进粒子群优化算法研究及应用[J]. 控制与决策, 2020, 35(8): 1871-1878.

[47] GAO S, YU Y, WANG Y, et al. Chaotic local search-based differential evolution algorithms for optimization[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2021, 51(6): 3954-3967.

[48] ZHAO J F, LIU K H, YOU Q, et al. Symmetry-aware short-term load forecasting in distribution networks: A synergistic enhanced KMA-MVMD-Crossformer framework[J]. Symmetry, 2025, 17(9): 1512.

[49] BOYD S, VANDENBERGHE L. Convex optimization[M]. Cambridge: Cambridge University Press, 2004.

[50] VASWANI A, BENGIO S, BREVDO E, et al. Tensor2Tensor for neural machine translation[C]//Proceedings of the 13th Conference of the Association for Machine Translation in the Americas. 2018: 193-199.

[51] KONG W, DONG Z Y, JIA Y, et al. Short-term residential load forecasting based on LSTM recurrent neural network[J]. IEEE Transactions on Smart Grid, 2019, 10(1): 841-851.

[52] SHI H, XU M, LI R. Deep learning for household load forecasting: A novel pooling deep RNN[J]. IEEE Transactions on Smart Grid, 2018, 9(5): 5271-5280.

[53] SEHOVAC L, GROLINGER K. Deep learning for load forecasting: Sequence to sequence recurrent neural networks with attention[J]. IEEE Access, 2020, 8: 36411-36426.

[54] BOUKTIF S, FIAZ A, OUNI A, et al. Optimal deep learning LSTM model for electric load forecasting using feature selection and genetic algorithm[J]. Energies, 2018, 11(7): 1636.

[55] WANG Y, CHEN Q, HONG T, et al. Review of smart meter data analytics: Applications, methodologies, and challenges[J]. IEEE Transactions on Smart Grid, 2019, 10(3): 3125-3148.

[56] 李昂, 王慧, 赵峰. 基于 CEEMDAN-LSTM 的短期电力负荷预测[J]. 电力系统保护与控制, 2021, 49(13): 84-91.

引用 [44]

元数据不一致

判断来源：联网证据核查
原文第 42 页

判断理由

Found but metadata disagrees: year cited=2022 vs source=2021.

证据来源

openalex ; Komodo Mlipir Algorithm ; 2021
https://doi.org/10.1016/j.asoc.2021.108043

引用 [50]

元数据不一致

判断来源：模型知识判断
原文第 42 页

判断理由

Tensor2Tensor for Neural Machine Translation确有相关AMTA 2018论文记录，但该项目常见作者列表通常更长，当前Vaswani、Bengio、Brevdo 三人列表可能不完整；会议及页码信息整体未显示出伪造迹象，建议核对正式作者顺序与页码。

[57] 刘洋, 张文, 余涛. 计及多元因素的配电网短期负荷预测方法[J]. 电网技术, 2021, 45(7): 2657-2665.

[58] HONG T, PINSON P, FAN S, et al. Probabilistic energy forecasting: Global energy forecasting competition 2014 and beyond[J]. International Journal of Forecasting, 2016, 32(3): 896-913.

[59] ZHANG J, WEI Y M, LI D, et al. Short term electricity load forecasting using a hybrid model[J]. Energy, 2018, 158: 774-781.

[60] CAI M, PIPATTANASOMPORN M, RAHMAN S. Day-ahead building-level load forecasts using deep learning vs. traditional time-series techniques[J]. Applied Energy, 2019, 236: 1078-1088.

[61] ASLAM S, HERODOTOU H, MOHSIN S M, et al. A survey on deep learning methods for power load and renewable energy forecasting in smart microgrids[J]. Renewable and Sustainable Energy Reviews, 2021, 144: 110992.

[62] TAN M, YUAN S, LI S, et al. Ultra-short-term industrial power demand forecasting using LSTM based hybrid ensemble learning[J]. IEEE Transactions on Power Systems, 2020, 35(4): 2937-2948.

[63] WANG S, WANG X, WANG S, et al. Bi-directional long short-term memory method based on attention mechanism and rolling update for short-term load forecasting[J]. International Journal of Electrical Power & Energy Systems, 2019, 109: 470-479.

[64] CHEN K, CHEN K, WANG Q, et al. Short-term load forecasting with deep residual networks[J]. IEEE Transactions on Smart Grid, 2019, 10(4): 3943-3952.

[65] GAO X, LI X, ZHAO B, et al. Short-term electricity load forecasting model based on EMD-GRU with feature selection[J]. Energies, 2019, 12(6): 1140.

[66] LI Y, CHE J, YANG Y. Subsampled support vector regression ensemble for short term electric load forecasting[J]. Energy, 2018, 164: 160-170.

[67] MASSAOUDI M, REFAAT S S, CHIHI I, et al. A novel stacked generalization ensemble-based hybrid LGBM-XGB-MLP model for short-term load forecasting[J]. Energy, 2021, 214: 118874.

[68] YILDIZ B, BILBAO J I, SPROUL A B. A review and analysis of regression and machine learning models on commercial building electricity load forecasting[J]. Renewable and Sustainable Energy Reviews, 2017, 73: 1104-1122.

[69] SUN X, WANG Z, HU J. Prediction interval construction for byproduct gas flow forecasting using optimized twin extreme learning machine[J]. Mathematical Problems in Engineering, 2017, 2017: 5120904.

[70] FAN C, WANG J, GANG W, et al. Assessment of deep recurrent neural network-based strategies for short-term building energy predictions[J]. Applied Energy, 2019, 236: 700-710.

[71] MEMARZADEH G, KEYNIA F. Short-term electricity load and price forecasting by a new optimal LSTM-NN based prediction algorithm[J]. Electric Power Systems Research, 2021, 192: 106995.

[72] UMass Trace Repository. UMass Smart* Dataset (2017 Release)[EB/OL]. (2017)[2025-06-01]. <https://traces.cs.umass.edu/docs/traces/smartstar/>.

[73] NIE Y, NGUYEN N H, SINTHONG P, et al. A time series is worth 64 words: Long-term forecasting with transformers[C]//International Conference on Learning Representations. 2023.

[74] ZENG A, CHEN M, ZHANG L, et al. Are transformers effective for time series forecasting?[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023, 37(9): 11121-11128.

[75] LIU Y, HU T, ZHANG H, et al. iTransformer: Inverted transformers are effective for time series forecasting[C]//International Conference on Learning Representations. 2024.

引用 [72]

元数据不一致

判断来源：模型知识判断
原文第 43 页

判断理由

UMass Smart* Dataset是已知的 UMass Trace Repository数据集资源，机构和主题基本可信；“2017 Release”与2025-06-01访问日期并存不构成真实性问题，但URL、版本标注和标点格式需规范化。

■ 红色 : AIGC / 改写倾向 ■ 橙色 : AI 润色倾向 蓝线 : 事实问题 紫线 : 引用问题 完整依据见页边批注及批注续页

[76] WANG S, WU H, SHI X, et al. TimeMixer: Decomposable multiscale mixing for time series forecasting[C]//International Conference on Learning Representations. 2024.

[77] WU H, HU T, LIU Y, et al. TimesNet: Temporal 2D-variation modeling for general time series analysis[C]//International Conference on Learning Representations. 2023.

[78] DAS A, KONG W, SEN R, et al. A decoder-only foundation model for time-series forecasting[C]//Proceedings of the 41st International Conference on Machine Learning. 2024.

[79] RASUL K, SEWARD C, SCHUSTER I, et al. Autoregressive denoising diffusion models for multivariate probabilistic time series forecasting[C]//Proceedings of the 38th International Conference on Machine Learning. 2021: 8857-8868.

[80] SALINAS D, FLUNKERT V, GASTHAUS J, et al. DeepAR: Probabilistic forecasting with autoregressive recurrent networks[J]. International Journal of Forecasting, 2020, 36(3): 1181-1191.

[81] WANG Y, GAN D, SUN M, et al. Probabilistic individual load forecasting using pinball loss guided LSTM[J]. Applied Energy, 2019, 235: 10-20.

[82] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. Journal of Computational Physics, 2019, 378: 686-707.

[83] KARNIADAKIS G E, KEVREKIDIS I G, LU L, et al. Physics-informed machine learning[J]. Nature Reviews Physics, 2021, 3(6): 422-440.

[84] HUANG B, WANG J. Applications of physics-informed neural networks in power systems: A review[J]. IEEE Transactions on Power Systems, 2023, 38(1): 572-588.

[85] COHEN T, WELLING M. Group equivariant convolutional networks[C]//Proceedings of the 33rd International Conference on Machine Learning. 2016: 2990-2999.

[86] BRONSTEIN M M, BRUNA J, COHEN T, et al. Geometric deep learning: Grids, groups, graphs, geodesics, and gauges[J]. arXiv preprint arXiv:2104.13478, 2021.